

REDES NEURAIIS ARTIFICIAIS APLICADAS AO PROCESSAMENTO DE IMAGENS

Tiago Ferreira SANTOS (1); Clarissa Gomes de SOUSA (2)

(1) CEFET-PB, Av. 1º de Maio, 720 Jaguaribe João Pessoa – PB, e-mail: tiagoferreira_22@yahoo.com.br

(2) CEFET-PB, e-mail: ligiomar@bol.com.br

RESUMO

O cérebro humano sempre foi alvo de estudos aprofundados na tentativa de desvendar seu funcionamento. Ao longo do tempo questões foram sendo resolvidas e, simultaneamente, criadas acerca do assunto. Em um dado momento, esse funcionamento ficou um pouco mais claro. A partir desse ponto e, baseado nessa maneira de funcionar, buscou-se reproduzir essa estrutura humana e seu funcionamento de forma artificial, criando-se então as redes neurais artificiais, ou simplesmente RNA's, voltadas para a resolução de problemas complexos com um desempenho superior a dos modelos convencionais. Essa pesquisa visa fornecer uma visão geral para aqueles que desejam conhecer um pouco mais a respeito destes fascinantes sistemas, explicando qual a motivação para a criação dessas estruturas, mostrar como funcionam as RNA's, os tipos de infra-estruturas, quais as redes mais utilizadas, suas aplicações, focando o processamento de imagens e analisá-lo, bem como as contribuições pioneiras nessa tecnologia.

Palavras-chave: redes neurais, funcionamento, aplicações, estruturas.

1. INTRODUÇÃO

O cérebro possui muitas características que são desejadas em sistemas artificiais, e a tentativa de simular a rede neural do cérebro motivou a criação das Redes Neurais Artificiais (RNA's), justificando o estudo da computação neural. Braga et al. (2000), em "Sistemas Inteligentes", afirmam que as RNA's são modelos matemáticos semelhantes às estruturas neurais biológicas e que tem capacidade computacional adquirida por meio de aprendizado e generalização. É através da experiência que estas redes adquirem conhecimento e podem ser utilizadas na resolução de diversos tipos de problemas encontrados em diferentes áreas aplicadas: classificação, identificação, diagnóstico, análise de sinais e de imagens, otimização e controle.

Tendo se mostrado um dos ramos da inteligência artificial que mais se desenvolve, as RNA's têm-se mostrado de fácil implementação, robusta no tratamento de dados com ruído e eficientes especialmente nos problemas em que não se tem uma formulação analítica ou um conhecimento explícito acessível, ou o próprio problema modifica-se com o tempo.

Tradicionalmente, os métodos mais comuns de processamento de imagens exigem uma representação matemática que, normalmente, é de difícil modelagem. Assim, uma técnica alternativa que deve ser estudada é a aplicação de Redes Neurais Artificiais (RNA's), pois trata-se de uma abordagem moderna de inteligência artificial que é capaz de classificar, generalizar e aprender funções desconhecidas e que pode obter os resultados desejados de maneira otimizada.

2. HISTÓRICO

Os trabalhos sobre redes neurais se iniciaram na década de 40, na Universidade de Illinois, com o neurofisiologista Warren McCulloch e o matemático Walter Pitts, cujas idéias foram publicadas no artigo *A Logical Calculus of the Ideas Immanent in Nervous Activity* (McCULLOCH e PITTS, 1943). No artigo, McCulloch e Pitts descreveram um modelo simplificado, porém poderoso, do neurônio real, que é utilizado na maioria dos modelos de RNA's atualmente. O modelo, chamado MCP, é baseado na neurofisiologia de um neurônio e desempenha uma função de soma e threshold (limiar), onde o peso das conexões entre os nós corresponde às sinapses de um neurônio real.

Surgiu então a primeira teoria neurofisiológica para modificação de sinapses em neurônios reais (determinação do processo de aprendizagem do cérebro), criada por Donald Hebb (1949). De acordo com sua teoria, "se um neurônio *A* é repetidamente estimulado por um Neurônio *B*, ao mesmo tempo em que ele está ativo, *A* ficará mais sensível aos estímulos de *B*, e a conexão sináptica de *B* para *A* será mais eficiente. Deste modo, *B* achará mais fácil estimular *A* para produzir uma saída". Esse procedimento de ajuste de pesos, frequentemente chamado de regra de Hebb, tem sido adotado de formas diferentes em algoritmos de aprendizado para modelos de RNA's baseados no modelo MCP.

Em 1959, Frank Rosenblatt criou o *Perceptron* (ROSENBLATT, 1959), que deu posteriormente origem aos modelos denominados de MLP. Alguns outros modelos similares ao Perceptron foram também desenvolvidos nesta época, como é o caso do *Adaline* (Adaptive Linear Element), criado por Bernard Widrow em 1962 (WIDROW, 1962). Os modelos do tipo Perceptron, incluindo o Adaline, são baseados no aprendizado supervisionado por correção de erros, uma classe muito importante de redes neurais artificiais, que possui uma larga aplicação na atualidade.

Após duas décadas de certo desinteresse na área, na década de 80 houve um grande interesse nesse paradigma com o surgimento de algoritmos de aprendizado mais eficiente para redes multiníveis, como o modelo de Hopfield (HOPFIELD, 1982), das máquinas de Boltzmann (HINTON, SEJNOWSKY e ACKLEY, 1985), do algoritmo Backpropagation (RUMELHART, HINTON e WILLIAMS, 1985, 1986), do modelo de redes multi-nível com Backpropagation (chamado de *Multi-Layer Perceptron – MLP*), outro modelo importante que surgiu nessa década foi o modelo de Teuvo Kohonen [1982, 1987]. O modelo de Kohonen é muito interessante, pois permite o aprendizado competitivo com uma auto-organização da rede neural, criando os chamados "mapas de atributos auto-organizáveis" (*self-organizing feature maps*).

3. CARACTERÍSTICAS GERAIS DAS RNA'S (FUNCIONAMENTO)

Uma RNA é composta por várias unidades de processamento, cujo funcionamento é bastante simples. Essas unidades geralmente são conectadas por canais de comunicação que estão associados a determinado peso. As unidades fazem operações apenas sobre seus dados locais, que são entradas recebidas pelas suas conexões. O comportamento inteligente de uma RNA vem das interações entre as unidades de processamento da rede.

A operação de uma unidade de processamento, proposta por McCulloch e Pitts em 1943, pode ser resumida da seguinte maneira:

- Sinais são apresentados à entrada;
- Cada sinal é multiplicado por um número, ou peso, que indica a sua influência na saída da unidade;
- É feita a soma ponderada dos sinais que produz um nível de atividade;
- Se este nível de atividade exceder um certo limite (threshold) a unidade produz uma determinada resposta de saída.




Figura 1 – Esquema de unidade McCulloch - Pitts.

Supondo que se tem p sinais de entrada X_1, X_2, \dots, X_p e pesos w_1, w_2, \dots, w_p e limitador t ; com sinais assumindo valores booleanos (0 ou 1) e pesos valores reais.

Neste modelo, o nível de atividade a é dado por:

$$a = w_1X_1 + w_2X_2 + \dots + w_pX_p$$

A saída y é dada por:

$$y = 1, \text{ se } a \geq t \text{ ou}$$

$$y = 0, \text{ se } a < t.$$

A maioria dos modelos de redes neurais possui alguma regra de treinamento, onde os pesos de suas conexões são ajustados de acordo com os padrões apresentados. Em outras palavras, elas aprendem através de exemplos.

Usualmente, as camadas são classificadas em três grupos:

- **Camada de Entrada:** onde os padrões são apresentados à rede; Arquiteturas neurais são tipicamente organizadas em camadas, com unidades que podem estar conectadas às unidades da camada posterior.
- **Camadas Intermediárias ou Escondidas:** onde é feita a maior parte do processamento, através das conexões ponderadas; podem ser consideradas como extratoras de características;
- **Camada de Saída:** onde o resultado final é concluído e apresentado.

4. ARQUITETURAS DE RNA'S

A maneira como são organizados os neurônios em uma rede neural está intrinsecamente ligada ao tipo de problema que será solucionado e é um fator essencial para a definição dos algoritmos de aprendizado a serem utilizados. A arquitetura das redes neurais pode ser dividida em três grupos básicos: Redes Neurais Diretas (*feed-forward*) e Redes Neurais Recorrentes (*feed-back*) e Redes Neurais Auto-Organizáveis.

4.1. Redes Neurais Diretas (*feed-forward*) ou acíclicas

Uma rede neural *feed-forward* consiste de uma ou mais camadas de unidades de processamento não-lineares. As conexões entre unidades de camadas adjacentes são definidas por um conjunto de pesos sinápticos. No entanto, para ser considerada *feed-forward*, uma rede neural precisa que suas saídas se conectem somente com as unidades da próxima camada. As primeiras redes de *feed-forward* a aparecerem na literatura foram Perceptron [ROSENBLATT, 1962] e Adaline [WIDROW, 1987]. No entanto, o potencial das redes *feed-forward* só foi revelado com o surgimento das redes neurais multicamadas.




Figura 2 – Rede Neural Feed-Forward Multicamada com Alimentação Unidirecional

4.2. Redes Neurais Recorrentes (*feed-back*) ou cíclicas

Em redes *feed-back*, a saída de uma unidade de processamento pode conectar-se a uma de suas próprias entradas ou a uma entrada de outra unidade da mesma camada, ao contrário das redes *feed-forward* que não permite esse tipo de conexão. Nessa classe de arquiteturas, encontram-se as redes neurais recorrentes.




Figura 3 – Rede Neural *Feed-Back* ou Recorrente

4.3. Redes Neurais Auto-Organizáveis

Existem redes neurais que não podem ser classificadas com *feed-forward* ou *feed-back*, mas como auto-organizáveis. São redes que tanto o número de neurônios e camadas são dinâmicos. O ser humano tem a capacidade única de usar suas experiências passadas para adaptarem-se as mudanças imprevisíveis de seu ambiente. No contexto das redes neurais artificiais, tal adaptação é chamada de auto-organização.




Figura 4 – Rede Neural Auto-Organizável

5. PROCESSO DE APRENDIZADO DAS RNA'S

Para um determinado conjunto de dados, o algoritmo de aprendizado deve ser responsável pela adaptação dos parâmetros da rede, de maneira que, em um número finito de iterações do algoritmo, haja convergência para uma solução. O critério de convergência varia de acordo com o algoritmo e com o paradigma de aprendizado, mas pode envolver, por exemplo, a minimização de uma função-objetivo, a variação do erro de saída ou mesmo a variação das magnitudes dos vetores de peso da rede.

Basicamente, considera-se que o processo de aprendizado, ou treinamento da rede, tem como característica a ocorrência de estímulo da rede pelo meio externo através da apresentação do conjunto de dados. Como consequência deste estímulo, o algoritmo de aprendizado provoca mudança nos parâmetros da rede e,

finalmente, a mudança nos parâmetros acarreta em mudança no comportamento da RNA. Espera-se que a mudança gradual no comportamento da rede resulte em melhoria gradativa do seu desempenho.

Em Kovács et al. (1996), a modificação do processamento ou da estrutura de conhecimento de uma rede neural envolve a alteração do seu padrão de interconexão. Em princípio, isto pode ser feito de com o desenvolvimento de novas conexões, com a perda de conexões existentes na rede ou modificando os pesos das conexões já existentes. Os principais paradigmas de aprendizagem são: supervisionada, não supervisionada e por reforço.

5.1. Aprendizagem Supervisionada

Neste paradigma de aprendizagem, um *supervisor* possui conhecimento sobre o ambiente onde a rede está inserida. Um conjunto de amostras de *entrada-saída* representa este conhecimento. O ambiente, porém, não é conhecido. Os parâmetros da rede são ajustados pela combinação do sinal de entrada com um sinal de erro, que é a diferença entre a saída desejada e a fornecida pela rede.

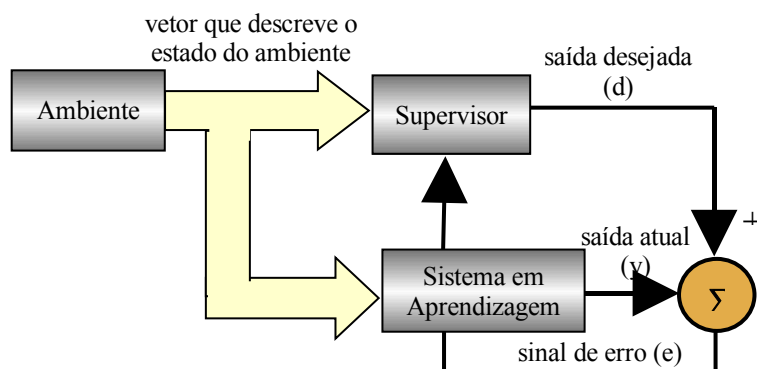


Figura 5 – Diagrama de blocos do processo de aprendizagem supervisionada

Considerando t como o índice que denota tempo discreto ou, mais precisamente, o intervalo de tempo do processo iterativo responsável pelo ajuste de pesos do neurônio k . O único sinal de saída $y_k(t)$, do neurônio k , é comparado com uma *saída desejada*, denominada $d_k(t)$. Conseqüentemente, um sinal de erro $e_k(t)$ é produzido:

$$e_k(t) = d_k(t) - y_k(t)$$

5.2. Aprendizagem Não-Supervisionada

No processo de aprendizagem não-supervisionada ou auto-organizada, não há supervisor que avalie o desempenho da rede em relação ao conjunto de treinamento (figura 6), ou seja, os dados são não-rotulados. A adaptação a regularidades estatísticas dos dados de entrada é uma característica da rede, que também desenvolve a habilidade de criar representações internas que codifiquem as características da entrada e, dessa forma, possa gerar novas classes automaticamente. Em geral, os algoritmos auto-organizados utilizam aprendizagem competitiva, onde existe uma “competição” entre os neurônios de saída da rede para que os mesmos se tornem ativos. A cada iteração, apenas um neurônio de saída é ativado. Esta característica torna o algoritmo apropriado para descobrir características estatísticas salientes, que podem ser utilizadas para classificar um conjunto de padrões de entrada.




Figura 6 – Diagrama de blocos do processo de aprendizagem não-supervisionada

5.3. Aprendizagem por Reforço

Visando minimizar um índice escalar de desempenho, a *aprendizagem por reforço* enfatiza a aprendizagem do indivíduo através da interação direta com o ambiente, sem se basear em um modelo completo ou uma supervisão deste ambiente. A Figura 8 ilustra um tipo de aprendizagem por reforço (HAYKIN, 1998) baseado em um crítico que converte um *signal primário de reforço* recebido do ambiente em um sinal de reforço de maior qualidade chamado *signal de reforço heurístico*. Ao invés de apenas tratar o erro atual, o objetivo desta aprendizagem é *minimizar uma esperança do erro acumulado*.

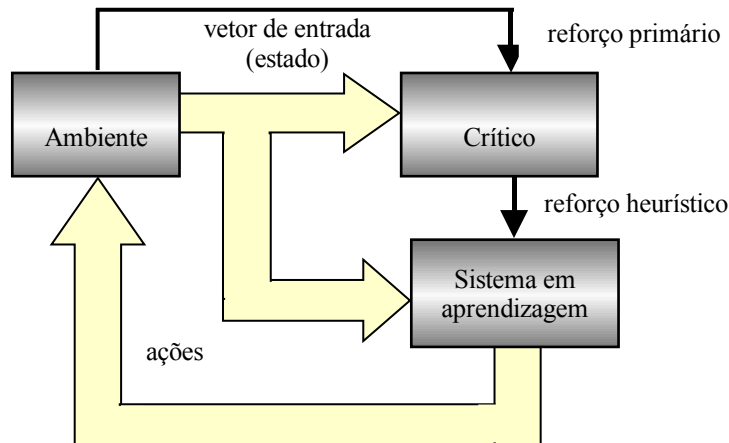


Figura 8 – Diagrama de blocos do processo de aprendizagem por reforço.

6. VISÃO ARTIFICIAL

A visão artificial é realizada através de um conjunto de transformações, algumas delas em paralelo, que permitem a extração dos aspectos invariantes das imagens, independentemente da variabilidade do ambiente no qual elas estejam inseridas. São estas invariâncias que possibilitam o reconhecimento ou a caracterização da imagem, permitindo a interação do sistema de visão com as mesmas. Logo, pode-se afirmar que a visão artificial busca “perceber” a informação contida numa imagem com o objetivo de classificar, caracterizar e/ou reconstruir a mesma.

Visão computacional, visão cibernética, visão de máquina, visão robótica e visão por computador são algumas das diversas denominações que têm sido dadas a este campo multidisciplinar, que aproveita os conhecimentos relacionados com Processamento de Sinais, Inteligência Computacional, Neurofisiologia entre outros. De uma forma geral, todos estes nomes indicam o processo de cognição de uma imagem, que pertence à área do Reconhecimento e Análise de Padrões.

São inúmeras as aplicações da visão artificial, podendo ser utilizada em qualquer campo onde se faça necessária para o reconhecimento de padrões visuais: Robótica, Medicina, Meteorologia, Astronomia, etc. Diversos projetos já foram desenvolvidos procurando construir sistemas visuais artificiais funcionais, sendo possível perceber que a maioria dos sistemas implementados, a exemplo de Acocella et al. (1993), seguem a mesma estrutura básica: *Pré-processamento*, *Extração de Características* e *Classificação* (Figura 9). Para cada uma dessas etapas, sua funcionalidade é apresentada a seguir:




Figura 9. Estrutura Básica de um Sistema de Visão Artificial.

6.1. Pré-Processamento

Na etapa de pré-processamento, é executada uma série de transformações na imagem de modo a extrair suas características intrínsecas. Assim como nos sistemas visuais biológicos (LEOW, 1994), o pré-processamento parte da matriz de pixels, obtida através de métodos que transformam os sinais luminosos em sinais elétricos.

Inicialmente, quando uma imagem é capturada, sempre existem informações pertencentes à cena que não interessam ao sistema, como, por exemplo, o fundo contra o qual a imagem se encontra. É necessário retirar os elementos desnecessários da imagem, aplicando-se um algoritmo de detecção de bordas. Retira-se, também, a influência que a fonte de luz tem sobre a imagem, num processamento conhecido como homomórfico (LIM, 1990). Posteriormente, o sistema de coordenadas também pode ser alterado.

Representando-se a imagem através de coordenadas polares, onde se obtêm os coeficientes harmônicos circulares e calculando-se a Transformada de Mellin (WU e STARK, 1986), o sistema torna-se invariante a operações como translação, escalonamento e rotação.

Após a aplicação desse conjunto de transformações locais, sustentadas pela Teoria de Processamento de Sinais, é obtida a “imagem intrínseca”. Esta representação da imagem original depende fortemente do tipo de operações que foram efetuadas sobre a imagem. A imagem passa a ser representada por uma matriz de coeficientes numéricos complexos e não mais por uma matriz de pixels.

6.2. Extração de Características

Uma vez obtidas as imagens intrínsecas de todas as classes de imagens que o sistema de visão artificial se propõe a classificar, é utilizado o extrator de característica, uma ferramenta auxiliar do classificador.

O extrator de características compara, de forma seqüencial, as representações das imagens intrínsecas e, através de métodos estatísticos, determina quais os coeficientes dessas imagens que apresentam maiores diferenças entre si. Estes serão os coeficientes que o classificador irá utilizar para tentar classificar uma imagem qualquer. Para os sistemas onde o classificador é desenvolvido com técnicas convencionais de análise, este módulo é fundamental, porque o conjunto de dados resultantes do pré-processamento da imagem é, em geral, muito grande para ser tratado de forma eficiente pelos métodos tradicionais. Por exemplo, no trabalho de Acocella, apenas 40 coeficientes, de um conjunto de cerca de 65.000, são utilizados na classificação.

7. PROCESSAMENTO DE IMAGENS BASEADO EM REDES NEURAIS ARTIFICIAIS

Uma das áreas de estudos mais interessantes da informática, inclusive geradora de um grande número de trabalhos junto à comunidade científica, é o processamento de imagens. As ferramentas de processamento de imagens têm permitido a realização inúmeras tarefas, tais como: a aquisição e transmissão de imagens digitais, o seu tratamento (filtros, compressão, processamento), e a extração e/ou identificação de seus componentes (reconhecimento de padrões). Estas tarefas vão à direção de um objetivo maior da área de inteligência artificial, que é o estudo e a reprodução da visão humana, ou seja, a área de visão artificial.

A necessidade do processamento de imagens é oriunda dos anos 20 e seu principal objetivo é a melhoria da informação pictográfica para análise humana e processamento de dados pelas máquinas [GONZALEZ, 1993]. Processar uma imagem consiste em modificar, analisar e manipular uma imagem digitalizada. E para o cumprimento destas ações, em geral, utilizam-se algoritmos baseados em princípios matemáticos [FACON, 1993] e [GONZALEZ, 1993].

Na figura 10 está esquematizado o uso do processamento gráfico (computação gráfica e processamento de imagens). Quando temos um conjunto de dados, imagens sintéticas podem ser criadas através de técnicas de computação gráfica. Também podemos obter dados através da visão computacional a partir destas imagens. Em ambos os casos, é preciso efetuar algum tipo de processamento, incluindo o tratamento de imagens.

Desta forma é possível concluir que o processamento de imagens pode ser aplicado após uma imagem ter sido criada por técnicas de computação gráfica ou pode ser usado inicialmente para facilitar o processo de visão computacional. O maior objetivo da utilização de RNA's no processamento de imagens é obter um sistema que supere os principais problemas do classificador convencional descrito na seção anterior: o exaustivo processamento de dados, associado à extração das características das imagens, e a pouca flexibilidade do sistema, que, para cada novo conjunto de objetos a serem classificados, necessita ser modificado.

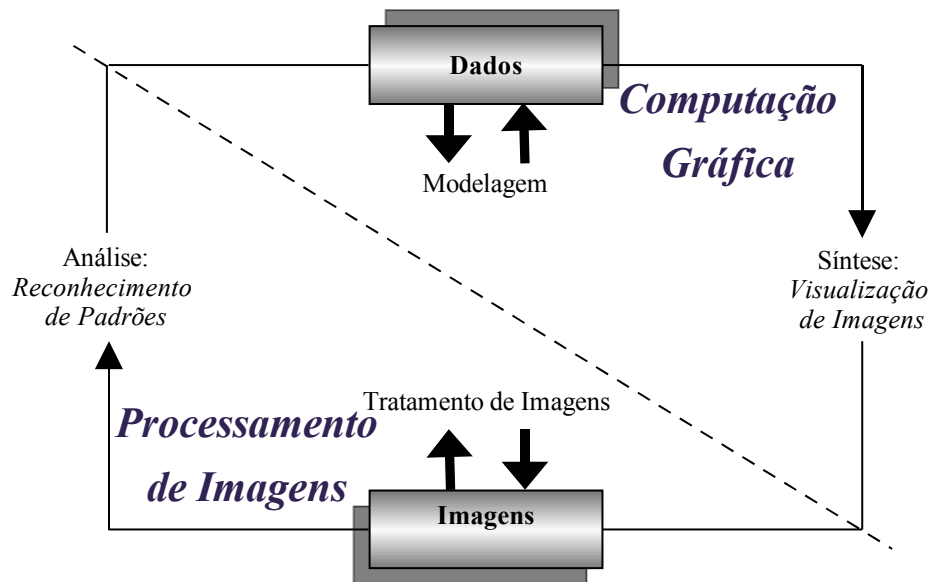


Figura 10 – Relação entre o processamento de imagens e a computação gráfica

Pode-se ver nesta figura que o processamento de imagens possui dois grandes eixos principais de atuação:

- **Tratamento de imagens:** a partir de uma imagem original, realiza-se uma transformação desta imagem, gerando, assim, uma nova imagem tratada. O tratamento de imagem inclui funções como: ressaltar/restaurar elementos de uma imagem, alterar seus componentes (transformar uma imagem colorida em preto e branco, aplicar um efeito especial) e corrigir distorções (melhorar o foco de uma imagem pouco nítida).
- **Reconhecimento de padrões:** a partir de uma imagem original, realiza-se um processamento que permite a análise esta imagem e a identificação de seus componentes. Dessa forma, é possível extrair uma descrição de alto nível dos seus componentes (modelo geométrico), agrupar os componentes que são similares, ou então realizar a classificação de seus componentes em grupos predefinidos (classes de objetos). As tarefas de reconhecimento de padrões podem ser facilmente implementadas através do uso de um algoritmo de aprendizado supervisionado, onde necessitamos apenas de um conjunto de exemplos de imagens previamente “etiquetadas” com as respectivas classes, a serem usadas no treinamento da rede.

O processamento de imagens convencional procura implementar as funções matemáticas que permitem realizar as transformações e análises das imagens através algoritmos predefinidos. O problema deste tipo de procedimento é que a função $F(x)$ que realiza esta transformação/classificação deve ser conhecida e bem especificada neste caso, conforme indicado na figura 11.

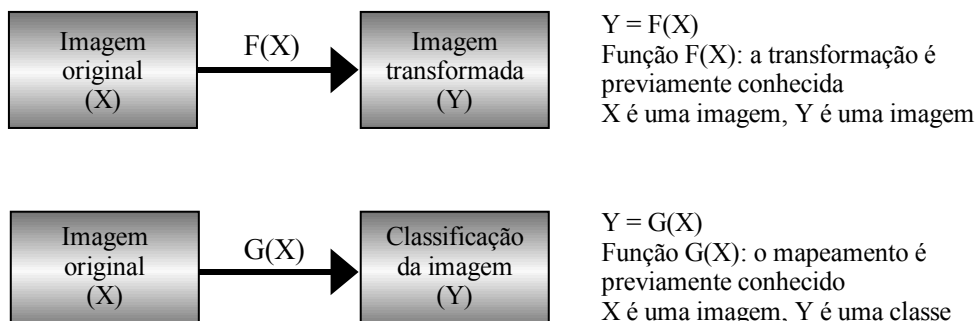


Figura 11 - Processamento de imagens convencional

Deseja-se obter a capacidade de executar o processamento de imagens sem conhecer a função transformadora, onde a própria aplicação fosse capaz de gerar a imagem desejada pelo usuário (Figura 12). O usuário irá fornecer apenas exemplos de imagens originais e do resultado desejado do tratamento destas, deixando para o

sistema a tarefa de “descobrir” uma maneira de realizar esta transformação (permitindo também que seja possível repetir novamente esta transformação sobre outras imagens).

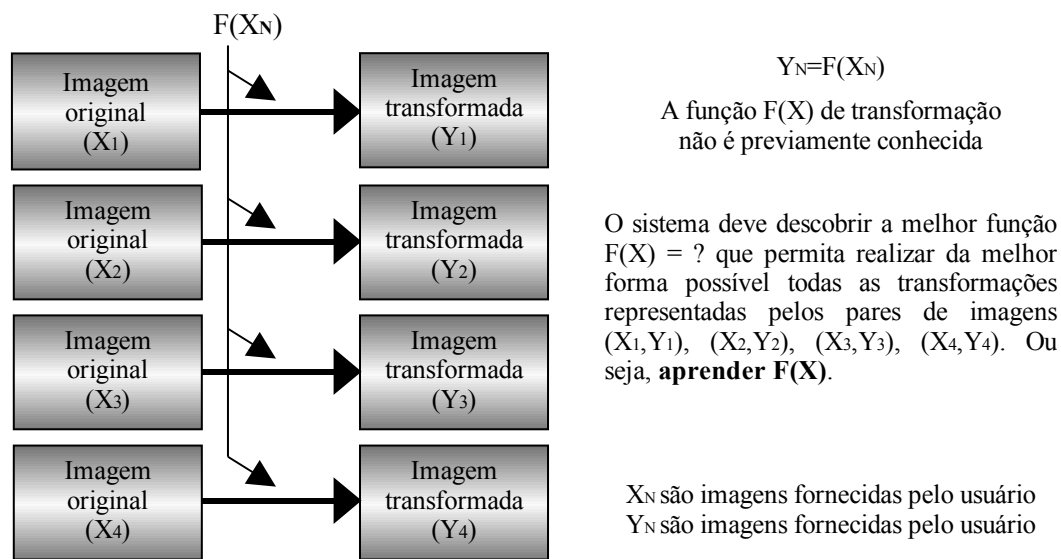


Figura 12 – Processamento de imagens usando o aprendizado

Nesse tipo de tratamento de imagens, o uso das Redes Neurais Artificiais é bastante adequado, pois essa ferramenta possibilita que se aprenda, partindo de um conjunto de exemplos, a realizar as transformações desejadas. Além disso, as RNA's também permitem que se trabalhe com: informações quantitativas (cores dos pixels – tanto valores de entrada como de saída da rede), generalização dos conhecimentos (a função obtida generaliza o filtro, dados os casos particulares), alta robustez das redes em relação ao ruído/erros e paralelismo no processamento dos dados.

REFERÊNCIAS

ACOCELLA, E. C. **Extração de Invariâncias em Processamento de Imagem Aplicado a Visão Computacional**. Tese de Mestrado IME, Rio de Janeiro, 1993.

BRAGA, A. P.; CARVALHO, A. C. P. L. F.; LUDEMIR, T. B. **Redes Neurais Artificiais – Teoria e Aplicações**. Rio de Janeiro: LTC Editora, 2000.

FACON, J. **Processamento e Análise de Imagens**. Córdoba. Universidade Nacional de Córdoba, 1993. 198p.

GONZALES, R. C.; WOODS, R. E. **Digital Image Processing**. Addison-Wesley Publishing, Reading. 1993. 716p.

HAYKIN, S. **Adaptive Filter Theory**. Prentice-Hall, 1992.

HEBB, D. O. **The Organization of Behaviour**. John Wiley & Sons. New York, 1949.

HINTON, G.; SEJNOWSKI, T.; ACKLEY, D. **Boltzmann Machines: Constraint Satisfaction Networks that Learn**. Carnegie-Mellon University – Tech. Report CMU-CS-84-119, 1984.

HOPFIELD, J. J. **Neural Networks and Physical Systems with Emergent Computational Abilities**. In: Proceedings of the National Academy of Sciences, v.79, Washington, USA. p.2554-2558, April 1982.

KOHONEN, T. **Self-Organized formation of Topologically Correct Feature Maps**. Biological

Cybernetics, v.43, p.32-48. January, 1982.

KOHONEN, T. **Self-Organization and Associative Memory**. Springer-Verlag Series in Information Science, 1987.

KOVÁCS, Z. L. **Redes Neurais Artificiais: Fundamentos e aplicações**. São Paulo , SP – Livraria da Física Editora, 1996.

LEOW, W.K. **Visor: Learning Visual Schemas in Neural Networks for Object Recognition and Scene Analysis**. Tese de Doutorado - Universidade do Texas, Austin, 1994.

LIM, J. S. **Two-Dimensional Signal and Image Processing**. Prentice-Hall, Englewood Cliffs, NJ, 1990.

McCULLOCH, W. S.; PITTS, W. **A Logical Calculus of the Ideas Imminent in Nervous Activity**. Bulletin of Mathematical Biophysics, 5, p.115-133, 1943.

ROSENBLATT, R. **Principles of Neurodynamics**. Spartan Books. New York. 1959.

RUMELHART, D. ; HINTON, G.; WILLIAMS, R. **Learning Internal Representations by Error Propagation**. ICS Report 8506, Institute for Cognitive Science, University of California at San Diego, La Jolla. September, 1985.

RUMELHART, D.; HINTON, G.; WILLIAMS, R. **Learning Internal Representations by Error Propagation..** *In*: Rumelhart & McClelland: Parallel Distributed Processing - Explorations in the Microstructure of Cognition - Vol.1: Foundations. Cambridge: MIT Press, 1986.

WU, R.; STARK, H. **Pattern Recognition in Practice II**. pp. 401-410, 1986.

WIDROW, B. **Generalization and Information Storage in Networks of ADALINE Neurons**. *In*: Self-Organization Systems. Spartan Books. Washington: p.435-461, 1962.

WIDROW, B.; WINTER, R. **Neural Nets for Adaptive Filtering and Adaptive Pattern Recognition**. IEEE Computer, New York, v.21, n.3, p.25-39. march, 1988.