

ESTUDO DE REDES NEURAIS TASOM PARA MODELAGEM DE CONTORNO ATIVO

Gabriel VASCONCELOS (1); Aida FERREIRA (2)

(1) CEFET-PE - Centro Federal de Educação Tecnológica de Pernambuco
Av. Prof Luiz Freire, 500 Cidade Universitária - Recife/PE, e-mail: gabrielvasconcelos_69@hotmail.com
(2) CEFET-PE, e-mail: aidaaf@gmail.com

RESUMO

Uma versão modificada de redes TASOM (*time adaptive self-organizing map*) com um número variável de neurônios foi proposta por Shah-Hosseini e Safabakhsh para modelagem de contorno ativo. Como nesta versão o contorno inicial pode ser definido dentro, fora, ou através do objeto, a extração do contorno deste objeto torna-se muito eficiente. Este contorno pode ser aberto ou fechado, pode ser tão simples como desejado, e pode ser colocado longe do objeto. Além disso, o objeto pode conter concavidades longas. Então, é proposta aqui uma adaptação do algoritmo de Shah-Hosseini e Safabakhsh para seu uso em imagens biomédicas, tendo em vista há necessidade dentro da medicina de se obter informações detalhadas a respeito da forma anatômica exata de partes do corpo humano. Este algoritmo é capaz de detectar pequenas variações sobre uma certa anatomia, auxiliando assim a análise e a tomada de decisões sobre a imagem, minimizando equívocos médicos. Os resultados experimentais comprovam a eficiência do algoritmo na detecção e extração de contornos de objetos em mamografias e mostram que o algoritmo proposto pode trabalhar com diferentes tipos de objeto e contornos iniciais.

Palavras-chave: Modelagem de contorno ativo; Redes neurais artificiais; Mapas auto-organizáveis; TASOM; Imagens biomédicas.

1. INTRODUÇÃO

Modelagem de Contorno Ativo (ACM) foi introduzido por Kass et. al. (1988) para modelagem de objetos fronteiras (objetos a serem contornados). Desde então, um número substancial de algoritmos foi sugerido na literatura para modelagem de contorno ativo. Um algoritmo ACM toma um contorno inicial definido para um objeto fronteira e modifica-o até o contorno se aproximar satisfatoriamente da borda do objeto fronteira. O contorno inicial é uma aproximação grosseira e o contorno final é uma representação precisa do objeto fronteira.

Modelagem de contornos de objetos utilizando mapas auto-organizáveis (SOM) também foi introduzida na literatura. Uma modificação do algoritmo SOM para modelagem de contorno ativo foi proposta em Venkatesh e Rishikesh (2000). O método usa um algoritmo SOM modificado com um número fixo de neurônios e uma topologia em cadeia, que pode ser usado para contornos abertos e fechados. Mas o algoritmo exige que o contorno inicial esteja perto do objeto fronteira, e o número de pontos sobre o contorno permaneça fixo. Estes pontos são os pixels da imagem que interceptam o contorno inicial. Colocar esse grande número de pontos sobre o contorno retarda a convergência do algoritmo. No entanto, o método converge para a solução correta para os exemplos utilizados nos experimentos (VENKATESH E RISHIKESH, 2000).

Um problema com a implementação da modelagem de contorno através de SOM é que algumas partes do contorno inicial podem estar mais perto dos pontos de recurso (pontos sobre o contorno do objeto fronteira) que as outras partes. Usando treinamento SOM, em tais casos, faz o contorno dobrado, ou algumas partes do contorno nunca se aproximam dos pontos recurso do objeto, especialmente quando o objeto fronteira inclui segmentos côncavos. A propagação não uniforme de pontos de controle (pontos que controlam o movimento do contorno em direção ao objeto fronteira) sobre o contorno é outro problema que ocorre nos algoritmos de modelagem que mantêm o número fixo de pontos controle sobre o contorno, incluindo aqueles baseados em redes SOM.

Redes *time adaptive self-organizing map* (TASOM) são formas modificadas de redes SOM. Similar à rede SOM, uma rede TASOM é composta de duas camadas: uma camada de entrada recebe os vetores de entrada, e uma camada de saída englobando os neurônios da rede. Existe uma taxa de aprendizagem individual e função de vizinhança para cada neurônio da TASOM, que são atualizadas com a próxima entrada de vetores. Em contraste, a SOM tem uma taxa de aprendizagem e função de vizinhança decrescente com o tempo, e são comuns a todos os neurônios.

À medida que neurônios se movem em direção aos dados de entrada, de acordo com as regras de atualização de pesos utilizadas em TASOM, que são as mesmas utilizadas em SOM, o algoritmo converge. Quando o neurônio chegar perto dos dados de entrada, os parâmetros de aprendizagem TASOM diminuem. Isso garante a estabilidade do algoritmo. À primeira vista, pode parecer que usar a taxa de aprendizagem e função de vizinhança individual fará o algoritmo lento. É verdade que cada iteração do algoritmo TASOM leva mais tempo do que o SOM, mas o número de iterações necessárias para a convergência do algoritmo TASOM é muito menor do que o SOM. Esta capacidade vem da dinâmica da atualização das taxas de aprendizagem e das funções de vizinhança. Quando os dados de entrada estão longe dos pesos TASOM, a taxa de aprendizagem e a função de vizinhança aumentam o que resulta no rápido movimento dos pesos em direção aos dados de entrada. As taxas de aprendizagem e as funções de vizinhança diminuem quando os pesos chegam perto dos dados de entrada, a fim de permitir que os pesos se aproximem melhor da distribuição de entrada. Uma discussão sobre a matemática TASOM é dada em Shah-Hosseini e Safabakhsh (2002).

Esta pesquisa foi idealizada com o objetivo de auxiliar interpretações de imagens biomédicas (imagens digitais representativas do corpo humano), tendo em vista há necessidade dentro da medicina de se obter informações detalhadas a respeito da forma anatômica exata de partes do corpo humano. As imagens biomédicas são obtidas através de procedimentos como ressonância magnética, raios-X, tomografia computadorizada, etc. Onde é difícil especificar automaticamente as regiões de estudo, a fim de detectar pequenas variações sobre uma certa anatomia.

Existe ainda a problemática do ruído, com a qual imagens médicas se deparam frequentemente. O algoritmo proposto é tolerante a ruído, o que facilita a interpretação da imagem para a detecção do contorno desejado.

Neste trabalho, portanto, propomos uma modificação do algoritmo ACM usando uma rede TASOM, conforme Shah-Hosseini e Safabakhsh (2002), para detecção e extração de contornos em imagens biomédicas, especificamente mamografias.

2. FUNDAMENTAÇÃO TEÓRICA

2.1. Inteligência Artificial

A inteligência artificial (IA) pode ser definida como uma área de estudos da computação que se interessa pelo estudo e criação de sistemas que possam exibir um comportamento inteligente e realizar tarefas complexas com um nível de competência que é equivalente ou superior ao de um especialista humano.

A IA engloba fundamentos de matemática, física, computação, lingüística, sociologia, psicologia, filosofia, genética e neurofisiologia. Possui diversas aplicações: previsões meteorológicas, do mercado financeiro, reconhecimento de padrões, sistemas de segurança (detecção de intruso), processamento de sinais, produção de jogos entre outras.

Os trabalhos com IA se dividem em grandes linhas de pesquisa:

- IA Simbólica: baseada na hipótese do sistema de símbolos físicos, segundo a qual um conjunto de estruturas simbólicas e um conjunto de regras de manipulação dessas estruturas são os meios necessários e suficientes para se criar inteligência
- IA Conexionista: baseada na hipótese da causa-efeito, segundo a qual um modelo suficientemente preciso do cérebro humano é suficiente para reproduzir a inteligência que o cérebro real possui.
- IA Evolucionária: baseada na teoria evolutiva de Darwin, a hipótese é que podemos modelar sistemas inteligentes simulando a evolução de uma população de indivíduos (soluções aleatórias), que carregam genes com informação suficiente para solução de um problema, usando operações, genéticas de recombinação e mutação. Essa linha de pesquisa trata de problemas de otimização e seu principal produto são os algoritmos genéticos.

Há também uma quarta linha de pesquisa, denominada IA Híbrida, na qual se combinam ferramentas de outras linhas para se obter a solução de um problema.

Inserida no paradigma conexionista está rede neural artificial (RNA), que simula a estrutura e a funcionalidade de uma rede neural biológica com o objetivo de desenvolver sistemas inteligentes. As redes neurais artificiais consistem em um método de solucionar problemas de inteligência artificial.

2.1.1. Rede Neural Artificial

Uma rede neural artificial, em sua forma mais geral, é uma máquina que é projetada para modelar a maneira como o cérebro realiza uma tarefa particular ou função de interesse. É normalmente implementada utilizando-se componentes eletrônicos ou é simulada por programação. Para alcançarem um bom desempenho, as redes neurais artificiais empregam uma interligação de células computacionais simples denominadas neurônios artificiais ou unidades de processamento (HAYKIN, 2001) e (BRAGA et. al., 2000).

Segundo Haykin (2001) uma rede neural artificial é um processador maciço e paralelamente distribuído constituído de unidades de processamento simples, que têm uma tendência natural para armazenar conhecimento experimental e torná-lo disponível para o uso. Isso é possível porque as redes neurais têm a habilidade de aprender a partir de seu ambiente e de melhorar o seu desempenho através desta aprendizagem. O conhecimento acerca do seu ambiente é adquirido por processos interativos de ajustes aplicados a seus pesos sinápticos (sinapses são unidades estruturais e funcionais elementares que medeiam as interações entre os neurônios). Idealmente, a rede neural se torna mais instruída sobre seu ambiente após cada interação do processo de aprendizagem.

Com isso, temos que uma rede neural artificial extrai seu poder computacional através de sua estrutura maciça paralelamente distribuída e de sua habilidade de aprender e, portanto, de generalizar. A generalização se refere ao fato de a rede neural produzir saídas adequadas para entradas que não estavam presentes durante o treinamento (aprendizagem). O tipo de aprendizagem é determinado de acordo com a maneira pela qual a modificação dos parâmetros ocorre. Não há um único algoritmo de aprendizagem (conjunto de procedimentos bem-definidos para adaptar os parâmetros de uma rede neural artificial para que

a mesma possa aprender uma determinada função) para um projeto de redes neurais artificiais, basicamente estes algoritmos diferem entre si pela forma como é formulado o ajuste de um peso sináptico de um neurônio, cada qual oferecendo vantagens específicas.

O algoritmo de aprendizado proposto neste trabalho, como já foi dito, baseia-se no algoritmo de Shah-Hosseini e Safabakhsh (2002) que utiliza uma rede neural artificial TASOM.

2.1.1.1. Redes SOM

As redes mapas *self-organizing* (SOM), também chamadas de mapas de características *self-organizing* (SOFM) foram desenvolvidas na década de 80 pelo pesquisador finlandês Teuvo Kohonen. Estas redes possuem uma forte inspiração neurofisiológica, sendo baseadas no mapa topológico presente no córtex cerebral. Os neurônios dessas áreas estão espacialmente ordenados, e assim neurônios topologicamente próximos tendem a responder a padrões ou estímulos semelhantes. Sabe-se que essa ordenação topológica é resultado do uso de *feedback lateral* entre as células do córtex cerebral. Esse *feedback lateral* é geralmente modelado em RNA por uma função conhecida como chapéu mexicano (ver Figura 1).




Figura 1 - Regiões de estímulos produzidos de acordo com a Função chapéu mexicano.

Segundo a função chapéu mexicano cada neurônio influencia o estado de ativação de seus neurônios vizinhos de três formas possíveis:

- Excitatória: se os vizinhos estão próximos a ele (região 1).
- Inibitória: se os vizinhos estão fora da área anterior, mas dentro de uma segunda área (região 2).
- Levemente excitatória: se os vizinhos estão fora das áreas anteriores, mas dentro de uma terceira área (região 3).

Braga et al. (2000) cita que a rede SOM funciona basicamente da seguinte forma: quando um padrão p é apresentado, a rede procura a unidade mais parecida com p . Durante seu treinamento a rede aumenta a semelhança do nodo escolhido e de seus vizinhos ao padrão p . Dessa forma a rede constrói um mapa topológico onde os nodos topologicamente próximos respondem de forma semelhante a padrões de entrada semelhantes. Segundo Haykin (2001), um mapa *self-organizing* é, portanto, caracterizado pela formação de um mapa topográfico dos padrões de entrada no qual as localizações espaciais (isto é, as coordenadas) dos neurônios na grade são indicativas das características estáticas intrínsecas contidas nos padrões de entrada, daí o nome “mapa auto-organizável”.

A rede SOM é uma rede biologicamente plausível, ou seja, apresenta respaldo biológico. Assim como no córtex cerebral, nodos ativos apresentam conexões mais fortes com nodos que estão fisicamente mais próximos.

2.1.1.2. Redes TASOM

Redes TASOM (*time adaptive self-organizing map*), Shah-Hosseini e Safabakhsh (2002), são formas modificadas de redes SOM. Algumas propriedades interessantes da rede TASOM torná-a uma boa escolha para o uso em ACM. Uma propriedade da TASOM é que ela usa a taxa de aprendizagem e função de vizinhança individual para cada neurônio. Isto torna a TASOM mais flexível na aproximação à distribuição

de entrada. Outra propriedade das redes TASOM é que elas usam taxas de aprendizagem e funções de vizinhança independentes, que são atualizadas com base nas condições ambientais em cada iteração do algoritmo de aprendizado TASOM. Assim, a TASOM supera os problemas causados pela utilização de taxas de aprendizagem e funções de vizinhança decrescentes com o tempo em redes SOM. A taxa de aprendizagem e função de vizinhança das redes SOM tem seus valores mais altos no início da aprendizagem. Então, eles diminuem com o passar do tempo, para que o recurso estabilize o mapa e aprenda a topografia do mapa do ambiente. Esta é, aliás, a razão pela qual a SOM pode não funcionar em ambientes não-estacionários. Outro problema é que a adição ou remoção do neurônio não pode ser implementada na rede SOM.

O TASOM pode aprender continuamente e seguir as mudanças do ambiente. Esta característica torna o TASOM menos sensível aos valores de parâmetros constantes e adequado para uso em ambientes não-estacionários. Faz também adição e remoção de neurônio com uma implementação não muito complexa.

Outra propriedade interessante da TASOM é que, embora seja mais complexa do que a rede SOM, ela converge mais rapidamente do que o algoritmo SOM, como demonstrado em Shah-Hosseini e Safabakhsh (2002).

2.2. Modelagem de Contorno Ativo

Modelos de contorno ativo (ACM) são curvas geradas por computador que se movem nas imagens para encontrar contornos de objetos. Elas são usadas frequentemente em visão computacional e análise de imagem para localizar objetos e descrever sua forma.

As equações parciais diferenciais chamadas *snakes* são uma técnica de ACM. Elas foram implementadas usando o método da diferença finita implícita ou programação dinâmica ou o método de elementos finitos. Sendo os dois primeiros os mais utilizados na literatura (FERREIRA et. al. 2006). Uma *snake* pode ser usada para contornar objetos de interesse presentes em uma imagem médica.

2.3. Imagens Digitais

De acordo com Gonzalez e Woods (2002), uma imagem pode ser definida como uma função bidimensional, $f(x,y)$, onde x e y são coordenadas espaciais e a amplitude de f em qualquer ponto (x,y) dá a intensidade ou o nível de cinza da imagem nesse ponto. Quando x , y e os valores da amplitude de f são quantidades discretas, a imagem é uma imagem digital.

Uma imagem digital é em geral composta por um número finito de elementos, cada um dos quais tem uma localização e um valor de intensidade particular. Esses elementos são conhecidos como pixels (*picture element*). Um pixel é o elemento básico em uma imagem. A forma mais comum para o pixel é a forma retangular ou quadrada. O pixel é também um elemento de dimensões finitas na representação de uma imagem digital. Frequentemente, a organização de uma imagem sob a forma de uma matriz de pixels é feita em uma simetria quadrada.

A área de Processamento de Imagens vem na realidade do Processamento de Sinais. Os sinais, como as imagens, carregam uma determinada informação. Esta informação pode estar associada a uma medida ou pode estar associada a um nível cognitivo. Processar uma imagem consiste em transformá-la sucessivamente com o objetivo de extrair mais facilmente a informação nela presente.

2.3.1. Processamento de Imagens Digitais

Segundo Ballard e Brown (1982) o primeiro passo no processo é a aquisição da imagem. Para tanto, necessitamos de um sensor para imageamento e necessitamos também digitalizar o sinal produzido pelo sensor. A natureza do sensor e da imagem que ele produz são determinadas pela aplicação.

Após a obtenção de uma imagem digital, o próximo passo trata de pré-processar aquela imagem. A função chave no pré-processamento é melhorar a imagem de forma a aumentar as chances para o sucesso dos processos seguintes. O pré-processamento tipicamente envolve técnicas para o realce de contrastes, remoção de ruído e isoladamente de regiões cuja textura indique a probabilidade de informação alfanumérica.

O próximo estágio trata da segmentação. A segmentação subdivide uma imagem em partes ou objetos constituintes. O nível até o qual essa subdivisão deve ser realizada depende do problema sendo resolvido. Ou seja, a segmentação deve parar quando os objetos de interesse na aplicação tiverem sido isolados. Em

geral, a segmentação autônoma é uma das tarefas mais difíceis em processamento de imagens. Esse passo determina o eventual sucesso ou fracasso na análise de imagens. De fato, a segmentação efetiva quase sempre garante sucesso no reconhecimento. Por essa razão, um cuidado considerável deve ser tomado para se melhorar as chances de uma segmentação robusta.

A segmentação de imagens é um passo preliminar essencial na maioria dos problemas de reconhecimento de padrões e análise de cenas. A escolha de uma técnica de segmentação em relação à outra é ditada principalmente pelas características peculiares do problema sendo considerado.

A saída do estágio de segmentação é constituída tipicamente por dados em forma de pixels, correspondendo tanto à fronteira de uma região como a todos os pontos dentro da mesma. Em ambos os casos é necessário converter os dados para uma forma adequada ao processamento computacional. A primeira decisão que precisa ser feita é se os dados devem ser representados como fronteiras ou como regiões completas. A representação por fronteira é adequada quando o interesse se concentra nas características da forma externa, tais como cantos ou pontos de inflexão. A representação por região é adequada quando o interesse se concentra em propriedades internas, tais como textura ou a forma do esqueleto. Em algumas aplicações, entretanto, essas representações coexistem. Essa situação acontece em aplicações de reconhecimento de caracteres, que freqüentemente requer algoritmos baseados na forma da borda, bem como também esqueletos e outras propriedades internas.

A escolha de uma representação é apenas parte da solução para transformar os dados iniciais numa forma adequada para o próximo processamento computacional. Um método para descrever os dados também deve ser especificado, de forma que as características de interesse sejam enfatizadas. O processo de descrição, também chamado seleção de características, procura extrair características que resultem em alguma informação quantitativa de interesse ou que sejam básicas para discriminação entre classes de objetos.

O último estágio envolve reconhecimento e interpretação. Reconhecimento é o processo que atribui um rótulo a um objeto, baseado na informação fornecida pelo seu descritor. A interpretação envolve a atribuição de significado a um conjunto de objetos reconhecidos. A interpretação procura atribuir significado a um conjunto de entidades rotuladas.

É importante ter em mente que a visualização dos resultados do processamento de imagens pode acontecer na saída de qualquer passo anteriormente citado. Em alguns casos, nem mesmo todos esses módulos são necessários. Por exemplo, o realce de imagens para interpretação visual humana raramente vai além do estágio de pré-processamento. Em geral, funções de processamento que incluam reconhecimento e interpretação estão associadas com aplicações de análise de imagens nas quais o objetivo é a extração automática, ou mesmo parcialmente automática, de informação a partir de uma imagem.

3. MATERIAIS E MÉTODOS

3.1. Materiais

Os materiais necessários para o desenvolvimento da pesquisa foram livros disponíveis na biblioteca do Cefet-PE e UFPE, artigos científicos disponíveis na Internet e micro-computadores presentes nos laboratórios do curso de Tecnologia em Sistemas de Informação do Cefet-PE.

Para a codificação do algoritmo proposto neste trabalho foi utilizada a ferramenta *MATLAB* versão 7.3.0.267(R2006b) da *The MathWorks* (TODESCO, 1995), (MATSUMOTO, 2002).

3.2. Metodologia

A metodologia adotada na pesquisa foi inicialmente realizar uma revisão bibliográfica, sobre temas relevantes ao que se propõe este trabalho, para a construção de uma fundamentação teórica. Com o embasamento teórico foi iniciado o processo de desenvolvimento e avaliação da aplicação e no final do projeto um estudo de caso foi proposto para avaliar a aplicação desenvolvida. Durante todo o projeto foram elaborados relatórios mensais para acompanhamento do mesmo.

4. ANÁLISE E INTERPRETAÇÃO DOS DADOS

4.1. Análise do Problema

A detecção precoce do câncer de mama, tendo as mamografias como fonte de dados, vem sendo objeto de estudo explorado na área de auxílio a diagnósticos (NUNES, 2006). Na mamografia são procuradas estruturas que indicam a presença de anormalidades ou tumores. Entre esses elementos estão as microcalcificações, depósitos de cálcio de formatos e tamanhos variados. Devido ao tamanho reduzido dessas estruturas, a sua visualização em mamografias exige grande experiência do examinador e, mesmo assim, muitas vezes são passadas despercebidas, visto que o sistema de Raios-X pode apresentar várias limitações que prejudicam a nitidez da imagem. De grande interesse ainda são os “clusters” (aglomerações) de microcalcificações, pois são indicadores da necessidade de investigação mais aprofundada. Devido a esta dificuldade na área médica, é proposta aqui uma modificação do algoritmo de Shah-Hosseini e Safabakhsh, (2002) a fim de detectar pequenas variações sobre a anatomia da mama.

4.2. Resolução do Problema

O algoritmo proposto inicia a busca pelo contorno do objeto na imagem com apenas quatro neurônios. Estes neurônios vão se aproximando da borda do objeto através de funções e parâmetros que atualizam seus pesos a cada iteração do algoritmo. Apenas quando os quatro neurônios encontrarem algum ponto do contorno do objeto, novos neurônios serão adicionados à rede. A adição de novos neurônios é necessária devido ao fato de que apenas quatro neurônios não conseguiriam contornar toda a fronteira do objeto. Esta adição depende da distância entre cada neurônio já existente. As regras de adição de neurônios são similares as do algoritmo de Shah-Hosseini e Safabakhsh (2002). A grande mudança está no fato de que novos neurônios somente serão incluídos na rede TASOM se os neurônios antigos, os já existentes na rede, já estiverem sobre algum ponto da borda do objeto. Se estes novos neurônios não estiverem sobre o contorno, novas iterações serão realizadas até que todos os neurônios estejam sobre algum ponto do contorno. Somente quando todos os neurônios forem suficientes para contornar o objeto, ou seja, apenas quando as distâncias entre todos os neurônios estiverem dentro do intervalo estabelecido pelo algoritmo então não será mais necessária a inserção de novos neurônios. Conseqüentemente, o processo de detecção do contorno do objeto se encerrará.

O algoritmo proposto é eficiente para objetos com contorno fechado pois utiliza uma rede TASOM com uma topologia fechada, ou seja, um dos vizinhos do último neurônio é o primeiro neurônio.

Para o algoritmo ACM proposto, o número de iterações necessárias para a convergência do contorno depende de vários fatores. Depende em parte dos parâmetros do algoritmo e também de outros fatores que são comuns a todos os algoritmos ACM (a forma e o tamanho do contorno inicial). O tempo de convergência é dependente também da forma e dimensão do contorno do objeto. Para um objeto complexo contendo concavidades longas, a convergência vai demorar um pouco mais, em comparação com um objeto simples.

Diferentemente do algoritmo de Shah-Hosseini e Safabakhsh (2002) neste algoritmo não há uma rotina para exclusão de neurônios da rede. Isso ocorre devido a diferença no modo de adição entre os dois algoritmos, o proposto aqui não precisa remover nenhum neurônio já que não permitirá a adição desnecessária de neurônios à rede. O algoritmo proposto por Shah-Hosseini e Safabakhsh (2002) adiciona neurônios a cada nova iteração, dependendo dos parâmetros de distância utilizados. Isto faz com que o algoritmo fique muito mais lento, o que inviabilizava a sua utilização. Então é proposta aqui essa nova rotina de adição de neurônios à rede TASOM, onde novos neurônios somente serão inseridos na rede se todos os neurônios já existentes obtiverem sucesso na busca pelo contorno. O fato de a rede conter muitos neurônios torna moroso o processo de eleição do neurônio vencedor (o neurônio mais próximo da fronteira do objeto), processo este fundamental para a atualização dos parâmetros do algoritmo. Para evitar isto, o algoritmo proposto aqui modifica a rotina de adição de neurônios não deixando existir neurônios desnecessários. Além disso, todos os neurônios que já estão sobre o contorno do objeto não poderão mais concorrer para ser o neurônio vencedor.

É importante salientar que, conforme Shah-Hosseini e Safabakhsh (2002), não é provável que ocorra cruzamento do contorno definido pelo algoritmo. Outro aspecto interessante do algoritmo é que os pontos controle sobre o objeto movem-se muito lentamente. Assim, o contorno nunca cruza a fronteira do objeto.

4.3. Experimentos

Foram realizados experimentos com imagens criadas em editores simples de imagens com o objetivo de analisar o desempenho do algoritmo proposto, suas vantagens e limitações. Essas imagens possuem bordas bem definidas, no entanto foi acrescentado ruído as mesmas para analisar a capacidade de filtragem deste ruído pelo algoritmo (CAMAPUM, 2005), (BALLARD E BROWN, 1982), (RUSS, 1992). Foram utilizadas também imagens de mamografias (imagens radiológicas da mama) presentes no banco de dados *mini-MIAS database of mammograms* disponível na *World Wide Web* através do site <http://peipa.essex.ac.uk/info/mias.html>. Estas imagens foram úteis para a realização de um estudo de caso onde foi possível verificar o desempenho do sistema com imagens reais.

Para o contorno de objetos em imagens simples o algoritmo mostrou muito bom desempenho, filtrando ruído e contornando de maneira eficiente as imagens. Na Figura2 é mostrada a primeira imagem simples testada. Onde a Figura2(a) representa a imagem original usada para o experimento. Esta imagem filtrada com o *Filtro Mediana* (GONZALEZ E WOODS, 2002) é mostrada na Figura2(b). Os quatro neurônios iniciais são definidos como mostra a Figura2(c). O contorno inicial representado pela ligação entre os neurônios iniciais é mostrado a Figura2(d). Os neurônios finais e o contorno final são apresentados pelas Figura2(e) e pela Figura2(f) respectivamente.

Para realizar experimentos com imagens reais, foram utilizadas várias as mamografias da base de dados do *mini-MIAS database of mammograms*, aqui serão mostrados os experimentos com as imagens mdb001 e mdb028.

A Figura3 apresenta o experimento com a imagem mdb001. Esta imagem tem formato 1024x1024pixels e apresenta uma anomalia classificada como massa limitada com severidade benigna de acordo com *mini-MIAS database of mammograms*. A Figura3(a) mostra a imagem original, a Figura3(b), os neurônios iniciais e a Figura3(c), o contorno inicial. A Figura3(d) exhibe os neurônios finais definidos pelo algoritmo.

A Figura4 apresenta o experimento com a imagem mdb028. Esta imagem também tem formato 1024x1024pixels e também apresenta uma anomalia classificada como massa limitada, mas com severidade maligna. A Figura4(a) mostra a imagem original, a Figura4(b), os neurônios iniciais e a Figura4(c), o contorno inicial. A Figura4(d) exhibe o contorno final atingido pelo algoritmo.

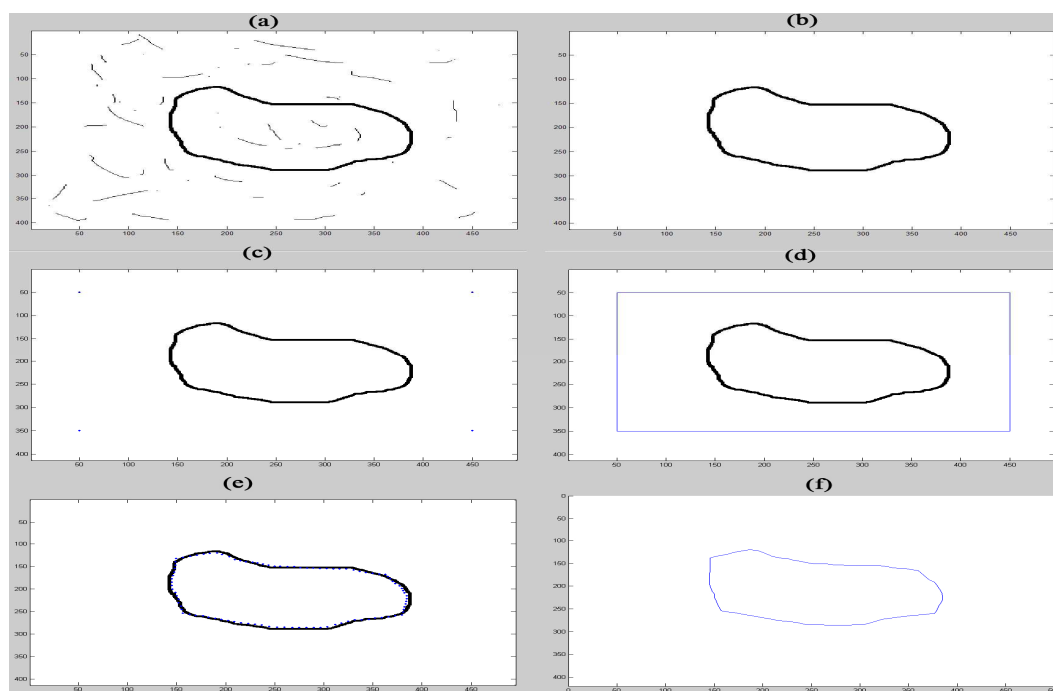


Figura 2 - Experimento com imagem simples. (a) Imagem Original (b) Imagem filtrada com filtro Mediana (c) Neurônios iniciais, pontos azuis na imagem (d) Contorno inicial, linhas em azul (e) Neurônios finais, pontos azuis sobre a imagem filtrada (f) Contorno final.




Figura 3 - Experimento com imagem mdb001. (a) Imagem Original (b) Neurônios iniciais, pontos verdes na imagem (c) Contorno inicial, linhas em azul (d) Neurônios finais, pontos verdes.




Figura 4 - Experimento com imagem mdb028. (a) Imagem Original (b) Neurônios iniciais, pontos verdes na imagem (c) Contorno inicial, linhas em azul (d) Contorno final traçado em azul.

5. CONCLUSÃO

Algumas propriedades da rede TASOM fazem com que ela seja atraente para utilização na modelagem de contorno ativo. As redes TASOM possuem taxas de aprendizado e funções vizinhança dinâmicas, diferentemente das redes SOM. Com isso, Shah-Hosseini e Safabakhsh (2002) propuseram um algoritmo para modelagem de contorno ativo utilizando redes TASOM. Então, foi proposta aqui uma versão do algoritmo de Shah-Hosseini e Safabakhsh (2002) com a finalidade de auxiliar na detecção de anormalidades em imagens biomédicas, especificamente mamografias.

As alterações propostas neste trabalho para o algoritmo de Shah-Hosseini e Safabakhsh (2002) reduziram significativamente o tempo de convergência do mesmo, fazendo com que o algoritmo alcance o resultado desejado de maneira mais rápida.

Os resultados experimentais mostram que a versão do algoritmo proposto pode trabalhar com diferentes tipos de objeto e contornos iniciais. As experiências comprovam a eficiência do algoritmo na detecção e extração de contornos de objetos em imagens biomédicas.

REFERÊNCIAS

- BALLARD, D.H.; BROWN, C.M. **Computer Vision**. Englewood Cliffs, New Jersey: Prentice-Hall Inc, 1982.
- BRAGA, A.P.; LUDERMIR T.B.; CARVALHO A.C.P.L.F. **Redes Neurais Artificiais: Teoria e Aplicações**. Rio de Janeiro: Editora LTC, 2000.
- CAMAPUM, J. F. **Introdução ao Processamento de Imagens Digitais**. VII Semana de Engenharia Elétrica, 2005.
- FERREIRA, A. A.; NASCIMENTO Jr, F. **Estudo de Redes Neurais SOM Baseadas em Isomorfismo Espacial para Modelagem de Contorno Ativo** in Projeto de Visão Computacional. Recife: UFPE, 2006.
- GONZALEZ, R.C.; WOODS, R. E. **Digital Image Processing**. Addison-Wesley Publishing Company, Massachusetts, 2a. Edição, 2002.
- HAYKIN, S. **Redes Neurais, Princípios e Prática**. 2.ed. Porto Alegre: Bookman, 2001.
- KASS, M.; WITKIN, A.; TERZOPOULOS, D. **Snakes: Active contour models**. Internat. J. Comput. Vision, 1988.
- MATSUMOTO, E.Y. **Matlab 6.5 Fundamentos de Programação**. São Paulo: Érica, 2002.
- NUNES, F.L.S. **Introdução ao Processamento de Imagens Médicas para Auxílio ao Diagnóstico – Uma Visão Prática**. São Carlos, 2006.
- RUSS, J.C. **The Image Processing Handbook**. CRC Press, 1992.
- SHAH-HOSSEINI, H.; SAFABAKHSH, R. **A TASOM-based algorithm for active contour modeling**. Pattern Recognition Letters, 2002.
- TODESCO, J. L. **Curso Introductório de MATLAB**. Universidade Federal de Santa Catarina, 1995.
- VENKATESH, Y.N.; RISHIKESH, N. **Self-organizing neural networks based on spatial isomorphism for active contour modeling**. Pattern Recognit, 2000.