

# Classificação de Elementos no Ambiente de Navegação Robótica Utilizando Redes de Kohonen

**Felipe A. PINAGÉ (1); Eulanda M. dos SANTOS (2); José P. QUEIROZ-NETO (3)**

(1) Universidade Federal do Amazonas - Av. Rodrigo Octávio, 3000 - Coroado I – Manaus / AM,

[felipepinage@gmail.com](mailto:felipepinage@gmail.com)

(2) Universidade Federal do Amazonas, [emsantos@dcc.ufam.edu.br](mailto:emsantos@dcc.ufam.edu.br)

(3) Instituto Federal do Amazonas, [pinheiro@ifam.edu.br](mailto:pinheiro@ifam.edu.br)

## RESUMO

As redes neurais artificiais são técnicas muito utilizadas em navegação robótica. Geralmente são aplicadas para auxiliar robôs autônomos a tomar direções corretas em até o alvo, consequentemente evitando obstáculos. As redes de Kohonen, mais especificamente, são muito usadas nesta área por apresentarem um aprendizado não-supervisionado. Este artigo apresenta um estudo experimental que utiliza as redes de Kohonen a fim de classificar os elementos presentes em um ambiente de navegação robótica, sendo que também é realizada a automação da análise de imagens digitais para apresentá-las à rede. Para isso, foi obtida uma base de dados com noventa imagens RGB (*Red, Blue, Green*) do ambiente de navegação. Na etapa de pré-tratamento dos dados, após a aquisição das imagens, elas são convertidas para o modelo HSI (*Hue, Saturation, Intensity*) de cores para então ser feita a segmentação que consiste em destacar os elementos presentes no ambiente. Os dados são apresentados à rede de Kohonen que realiza o treinamento buscando as similaridades entre as características e separando-as em *clusters*.

**Palavras-chave:** Mapas auto-organizáveis de Kohonen, Robótica, Processamento de Imagens

## 1 INTRODUÇÃO

A robótica móvel busca solucionar problemas relacionados à navegação em ambientes complexos. Para que o robô opere neste tipo de ambiente, é necessário que se possa extrair e utilizar informações adquiridas do lugar, como estimar posições, reconhecer obstáculos e ter a capacidade de se movimentar (RUSSEL & NORVIG, 2004). Nos últimos anos, pesquisadores da área de robótica têm se voltado para projetos que integram visão computacional com técnicas de aprendizagem de máquina para auxiliar na navegação de robôs móveis.

As redes neurais artificiais são técnicas de aprendizagem de máquina que têm sido aplicadas na solução de muitos problemas como, dentre eles em processamento digital de imagens e sinais e robótica. Essas técnicas computacionais são projetadas para imitar a estrutura biológica de neurônios em um cérebro humano. Uma de suas características é que um neurônio artificial pode ser treinado para responder aos padrões de entrada assim como ocorre com os neurônios biológicos. Portanto, caracterizam-se como técnicas que podem ser utilizadas em problemas de reconhecimento de padrões.

Existem diversos modelos de redes neurais, por exemplo: *Perceptron*, *Perceptron* Multi-camadas e rede de Kohonen, sendo as duas primeiras de aprendizado supervisionado.

O tipo básico de rede neural artificial tratado neste trabalho é a rede de Kohonen, também conhecida como SOM (*Self-Organizing Map*), devido ao uso de um algoritmo de treinamento não-supervisionado.

Treinamentos supervisionados precisam de um professor, pois é necessário comparar a saída da rede com a saída desejada. Já em treinamentos não-supervisionado, não é necessário professor, nem comparações. O algoritmo é preparado para modificar os parâmetros sem interferência externa, se tornando uma rede auto-organizada (WOJEWÓDZKI & RYBARSKI, 2006).

Geralmente em treinamentos não-supervisionados, algumas informações não são conhecidas previamente, o uso do SOM permite a visualização de um número de agrupamentos existentes na base de dados. Tal visualização da formação de agrupamentos de dados com características em comum através do SOM é uma ferramenta bastante poderosa para análise de sinais (MATOS et. al., 2004), por exemplo.

O objetivo deste trabalho é auxiliar a navegação de um robô autônomo, utilizando a rede de Kohonen para reconhecer os elementos presentes em seu ambiente, encontrando assim sua própria localização, o alvo a ser alcançado e os obstáculos a serem evitados. É apresentada à rede uma série de imagens com disposições diferentes dos elementos, a fim de obter um agrupamento correto e posteriormente a classificação dos mesmos. O objetivo final é buscar técnicas que melhorem, em termos de tempo e precisão, a percepção do ambiente por um robô autônomo e a definição de trajetórias mais eficientes, levando em consideração que a navegação robótica é uma área que está constantemente em busca da evolução.

A seção 2 apresenta a metodologia utilizada desde a descrição do ambiente e pré-tratamento dos dados até a descrição da rede de Kohonen como técnica de agrupamento utilizada. Na seção 3 são descritos os resultados obtidos, e finalizando com a seção 4, com as conclusões do trabalho.

## 2 METODOLOGIA

O sistema proposto utiliza técnicas de visão computacional e aprendizagem de máquina e tem como função principal realizar um agrupamento dos dados para uma eventual classificação através de uma análise visual feita pelo próprio programador. O sistema pode ser definido com os seguintes passos: aquisição das imagens do ambiente; processamento destas imagens para a segmentação dos elementos; apresentação destas imagens à rede de Kohonen, a qual realiza o treinamento e fornece como saída uma matriz de distância unificada (*U-Matrix*) e um mapa com as classes alocadas formando *clusters*. O diagrama com sequência dos passos pode ser observada na Figura 1.





Figura 1. Diagrama de passos para agrupamento dos dados.

### 2.1 Descrição do Ambiente

A configuração do cenário foi definida a partir da atribuição de cores para cada elemento disposto no ambiente, as cores foram escolhidas aleatoriamente, sendo a cor vermelha para o robô, verde para os obstáculos, azul para o alvo e preto pra o fundo.

O tamanho do ambiente deve ser definido *a priori*, tendo dimensões selecionadas correspondentes com os *pixels* do tamanho de uma imagem a ser capturada, permitindo a percepção de todos os elementos do ambiente (PINAGÉ, 2009).

A câmera foi posicionada perpendicularmente ao plano de cena, permitindo a captura de imagens sem oclusões dos elementos. Conforme a Figura 2.



**Figura 2. Ambiente de navegação do robô.**

## **2.2 Pré-tratamento dos Dados**

As imagens obtidas pela câmera inicialmente contém três amostras de elementos cada uma, e muitas características (os valores dos pixels da imagem), o que pode atrapalhar o agrupamento dos dados. Para isso, foi necessário reduzir as dimensões destas imagens, e realizar um processamento de segmentação para isolar os elementos e consequentemente reduzir também o número de características.

### **2.2.1 Aquisição das Imagens**

As imagens capturadas pela câmera são coloridas do tipo RGB, lidas como uma matriz bidimensional  $M(i,j)$ . Onde  $i$  são linhas e  $j$  são colunas. As dimensões das imagens apresentadas à rede são de 30x40.

### **2.2.2 Conversão RGB para HSI**

O espaço de cores HSI particiona uma cor em Matiz, Saturação e Intensidade, sendo a Matiz a cor propriamente dita, a Saturação identifica o quão forte é a cor e a Intensidade identifica a luminância da cor (PENHARBEL et. al., 2004).

Devido à facilidade de trabalhar com as cores na banda H, sem a interferência da iluminação, a conversão do modelo RGB para HSI foi realizada para que as cores pudessem ser separadas e os elementos segmentados. A conversão foi realizada aplicando-se uma sequência de fórmulas *pixel a pixel*, que podem ser conferida em (PINAGÉ, 2009).

### **2.2.3 Segmentação dos Elementos**

Para que se entenda como segmentar os elementos, é preciso entender sobre separação de cores.

É possível aplicar técnicas de processamento de tons de cinza em algum canal de imagem que use o modelo RGB, bastando para isso efetuar a devida separação dos canais e tratar a componente de cor como uma imagem em tons de cinza (GONZALEZ & WOODS, 2002).

Para segmentar os elementos realiza-se os seguintes passos (PINAGÉ, 2009):

1. Após a conversão de RGB para HSI realiza-se uma varredura da banda H, seus valores são dados em um intervalo  $[0,1]$ . Onde o vermelho é indicado por 0,9 graus, o verde por 0,2 graus, e o azul por 0,6 graus. Conforme exemplo mostrado no Algoritmo 1.
2. A partir desta varredura, são criadas três imagens, cada uma identificando um elemento. A cor do elemento em questão é detectada na banda H, sua cor é mantida no tom de cinza e o resto da imagem é pintado de preto;
3. Uma varredura nas bandas S e I ajudam em uma detecção mais precisa de cada cor, mas seus valores no algoritmo dependem da iluminação de cada imagem.

```

segmenta_robo(pixelH, pixelR){
    if (pixelH != 0,9) pixelR=0;
}

```

**Algoritmo 1. Técnica para segmentar os elementos.**


### 2.3 Redes de Kohonen (Mapas Auto-Organizáveis)

O objetivo do estudo apresentado neste artigo é a utilização de uma rede neural competitiva e não supervisionada, para ordenar, classificar e realizar agrupamentos dos elementos presentes em um ambiente de navegação robótica, a partir de suas cores. A rede de Kohonen apresenta um algoritmo de fácil implementação e realiza uma projeção não-linear dos dados multivariados num espaço bidimensional, sendo indicada para solucionar o problema proposto (FRANCISCO, 2004).

Esse método de aprendizado de máquina é utilizado para agrupamento de padrões, problemas de otimização e simulações. Captura as características importantes contidas no espaço de entrada multidimensional e desta forma, representa-o num espaço bidimensional (HAYKIN, 2001). Segundo (HAYKIN, 2001), depois de ter sido inicializada a grade, existem três fases essenciais envolvidas na formação do mapa auto-organizável: competitiva, cooperativa e adaptativa.

Na fase competitiva os neurônios competem entre si, calculando a distância Euclidiana em relação às entradas. O neurônio que apresentar a menor distância é o neurônio vencedor. Na fase cooperativa o neurônio vencedor excita os outros neurônios que se encontram dentro do seu raio de vizinhança. Finalmente, na fase adaptativa os neurônios excitados ajustam seus pesos sinápticos de acordo com os padrões de entrada. O que faz com que o mapa seja auto-organizável.

A vizinhança topológica decresce monotonicamente à medida que a distância entre o neurônio vencedor e o neurônio excitado aumenta, para isso existem algumas funções que satisfazem esta exigência. A função de vizinhança utilizada neste trabalho foi a função gaussiana (Figura 3). Segundo (HAYKIN, 2001), esta função apresenta uma forte cooperação entre o neurônio vencedor e os seus vizinhos.



**Figura 3. Função de vizinhança Gaussiana. Fonte (HAYKIN, 2001).**

As redes de Kohonen apresentam dois tipos de treinamento: sequencial ou por lote. Ambos apresentam um treinamento iterativo. O que os difere é que no treinamento por lote, não é necessário fornecer o parâmetro da taxa de aprendizagem, e ainda assim apresenta um bom desempenho.

#### 2.3.1 Algoritmo SOM

O algoritmo SOM foi desenvolvido por Teuvo Kohonen e realiza uma redução na dimensionalidade da rede. Conforme os passos podem ser observados a seguir (FRANCISCO, 2004).

1. Inicializar pesos, raio topológico, taxa de aprendizagem e número de iterações;
2. Apresentar os vetores de entrada à rede em ordem aleatória;
3. Treinamento da rede (fases: competitiva, cooperativa e adaptativa);

4. Atualização (raio topológico e taxa de aprendizagem são decrementados);
5. Terminar quando o número de iterações atingir o número máximo especificado no início.

### 3 RESULTADOS

O sistema de classificação dos elementos do ambiente foi realizado no ambiente computacional Matlab 7.8, implementado com a caixa de ferramentas SOM para Matlab 5 (*som toolbox*) (VESANTO et. al., 2000). Antes da realização dos treinos com a rede de Kohonen, primeiramente foram definidas 30 (trinta) diferentes organizações do ambiente, distribuindo os obstáculos (verde), o alvo (azul) e robô (vermelho). Imagens do tipo RGB com vista panorâmica do ambiente e sem oclusão de elementos (Figura 4) foram adquiridas.




Figura 4. Imagem do ambiente organizado.

Após a aquisição das imagens 40x30 *pixels*, foi necessário pré tratar as mesmas. As imagens foram então convertidas do modelo RGB para o modelo HSI. Apesar de o modelo RGB apresentar facilidades de operação, observamos que há muita sensibilidade à iluminação, sendo um problema no momento de segmentar os elementos.

A próxima etapa do pré-tratamento foi segmentar os elementos, os passos para este processamento foram realizados conforme explicados na Seção 2.2.3. E o resultado pode ser observado na Figura 5.




Figura 5. Resultado da segmentação dos elementos.


Após a segmentação dos elementos, o número de amostras para a rede de Kohonen aumentou para 90, observando que cada imagem foi subdividida em 3. Então, para a criação da base de dados, as imagens, que são lidas como matrizes bidimensionais, foram escritas como vetores de 1200 posições com a extensão *data*, exigida pela *som toolbox*. O tamanho dos vetores indica o número de características em uma amostra.

A base de dados inicial foi então particionada em base de treino e de validação, sendo que 60 imagens foram usadas na base de treino, e 30 na base de validação. Alguns parâmetros necessários para os treinos da rede de Kohonen também foram definidos, tais como: inicialização randômica e treino sequencial.

Nos primeiros testes, a rede apresentou baixo desempenho. Esse resultado já era esperado uma vez que a literatura mostra que o número de características das amostras não deve ser muito maior do que a quantidade de amostras disponível para o treinamento da rede. Esse fenômeno é conhecido como a “maldição da dimensão de entrada” (HAYKIN, 2001). Portanto, para melhorar a representação das características e consequentemente o desempenho do método de agrupamento, o vetor foi reduzido pela metade. Foram eliminadas apenas características que correspondiam ao fundo da imagem.

Novos treinamentos foram realizados com a nova descrição das amostras. Os parâmetros da rede permaneceram inalterados, ou seja, treino por lote e inicialização randômica. Apesar do treinamento por lote não precisar da taxa de aprendizagem, essa opção mostra-se mais eficiente quando tal parâmetro é apresentado. Portanto, foi utilizada uma taxa de aprendizagem de 0.5 na fase de ordenação e 0.05 na fase de convergência, o que aumentou consideravelmente o desempenho de agrupamento da rede.

Buscando melhorar ainda mais os resultados, o número de iterações, tanto na fase de ordenação quanto na fase de convergência foi aumentado consistentemente. Os resultados podem ser observados na Figura 6



**Figura 6. Classes dispostas em um mapa bidimensional após o treino.**

O mapa bidimensional mostrado na Figura 6 mostra que as amostras de alvo foram agrupadas praticamente sem erro, poucas amostras de obstáculos foram agrupadas de forma incorreta, enquanto que houve muito erro no agrupamento das amostras de robôs.

A partir do treinamento feito com 5000 iterações na fase de ordenação e 20000 iterações na fase de convergência (ajuste fino do mapa), na Tabela 1, é possível observar os erros, quantitativo, topográfico e o geral. O erro geral indica a porcentagem de amostras alocadas em células não pertencentes às regiões de seus agrupamentos.

**Tabela 1. Resumo do treinamento SOM.**

		N. Iterações	Erro		
			Quantitativo	Topográfico	Geral
TREINAMENTO	ORDENAÇÃO	5000	1,2	0,2	20,8%
	CONVERGÊNCIA	20000			
VALIDAÇÃO			0,9	0,1	8,7%

#### 4 CONSIDERAÇÕES FINAIS

O trabalho apresentou um sistema que utiliza uma técnica de aprendizagem de máquina para identificação de elementos presentes em um ambiente de navegação de robôs autônomos. O objetivo é auxiliar no rastreamento de trajetórias, mostrando também técnicas de processamento de imagens que auxiliam na extração de informações importantes.

A técnica usada no trabalho foi a rede de Kohonen, que apresenta um método não-supervisionado e por isso é capaz de agrupar os dados de entrada sem conhecimento *a priori* das saídas. Vale ressaltar que os testes foram feitos para analisar a eficiência e eficácia da técnica para sua aplicação em navegação robótica.

Visto que as redes de Kohonen geram suas saídas a partir dos padrões de entrada, elas funcionam como um sistema dinâmico de tal forma que a entrada e a saída (sinapses treinadas) do sistema estejam disponíveis para análise do comportamento dinâmico e para serem utilizados em sistemas em tempo real.

Durante o experimento observou-se um problema devido à má formação das características, e como cada vetor de amostra continha muitas características desnecessárias, o tamanho de cada vetor foi reduzido pela metade, o que melhorou consideravelmente o desempenho da rede. Entretanto, os erros obtidos podem ser reduzidos e considerados aceitáveis para o problema de navegação de robôs, devido ao auxílio de outros sensores que garantem a precisão na detecção de obstáculos e alvos.

O sistema desenvolvido apresenta limitações relacionadas ao ambiente, e teve a intenção de ser um passo para contribuir com a solução do problema da navegação robótica. Como trabalho futuro, as restrições que caracterizam o ambiente serão relaxadas e a base de dados será reavaliada no intuito de encontrar características melhores para aplicar a rede de Kohonen juntamente com técnicas de visão computacional, e por fim, rastrear trajetórias possíveis para robôs autônomos.

## REFERÊNCIAS

RUSSELL, S.; NORVIG, P. **Inteligência Artificial**. 2 ed. Rio de Janeiro: Elsevier, 2004.

WOJEWÓDZKI, S. H.; RYBARSKI, J. **The Kohonen Network Library**. Overload. v 74. p. 22-31, Agosto 2006.

MATOS, M. C., OSÓRIO, P. L. M., JOHANN, P. R. S. **Agrupamento de mapas auto organizáveis de Kohonen aplicado a análise de fácies sísmicas**. In: Anais do CBA 2004 (Congresso Brasileiro de Automática). Rio de Janeiro, RJ, 2004. Disponível em: [http://www.lps.ele.puc-rio.br/marcilio/publications/CBA2004\\_1079.pdf](http://www.lps.ele.puc-rio.br/marcilio/publications/CBA2004_1079.pdf). Acesso em: 20 jun. 2010.

PINAGÉ, F. A.; SILVA, I. A.; PINTO, L. D. O.; QUEIROZ-NETO, J. P. **Um Sistema Para Navegação Autônoma De Robôs Terrestres**. In: CONNEPI, IV, Belém, 2009.

PENHARBEL, E. A.; DESTRO, R. C.; TONIDANDEL, F.; BIANCHI, R. A. C. **Filtro De Imagem Baseado Em Matriz RGB De Cores-Padrão Para Futebol De Robôs**. Centro Universitário da FEI – UniFEI, São Bernardo do Campo, 2004.

GONZALEZ, R. C., WOODS, R.E. **“Digital Image Processing”**. 2. Nd., Prentice Hall, New Jersey, 2002.

HAYKIN, S. **Redes neurais: princípios e prática**. 2.ed. Tradução de, Paulo Martins Engel. Porto Alegre: Bookman, 2001.

FRANCISCO, C. A. C. **REDE DE KOHONEN: Uma ferramenta no estudo das relações tróficas entre espécies de peixes**. Dissertação de Mestrado em Ciências. Universidade Federal do Paraná, Curitiba, 2004.

VESANTO, J.; HIMBERG, J.; ALHONIEMI, E.; PARHANKANGAS, J. **SOM Toolbox for Matlab 5**. report A57, Abril 2000. Libella Oy: Finland: SOM Toolbox Team, Helsinki University of Technology, 2000b. 59 p., ill. Disponível em: <http://www.cis.hut.fi/projects/somtoolbox> . Acesso em: 20 Mai. 2010.