

MODELAGEM NEURAL DA FREQUÊNCIA DE RESSONÂNCIA DE ANTENAS PATCHES EM MICROFITA QUASE-FRACTAL

Adaildo G. D' ASSUNÇÃO (1); Elder Eldervitch C. DE OLIVEIRA (2); Ronaldo de A. MARTINS (3); João Bosco L. de OLIVEIRA (4);

(1) Universidade Federal do Rio Grande do Norte, Av Sen. Salgado Filho, s/n. CEP: 59072-970, Natal-RN, e-mail: adaildo@ct.ufrn.br

(2) Universidade Federal do Rio Grande do Norte, Av Sen. Salgado Filho, s/n. CEP: 59072-970, Natal-RN, e-mail: elder2@ymail.com

(3) Universidade Federal do Rio Grande do Norte, Av Sen. Salgado Filho, s/n. CEP: 59072-970, Natal-RN, e-mail: ronaldo@ufrnet.br

(4) Universidade Federal do Rio Grande do Norte, Av Sen. Salgado Filho, s/n. CEP: 59072-970, Natal-RN, e-mail: bosco@sedis.ufrn.br

RESUMO

As antenas de microfita estão em constante evidência nas pesquisas atuais, isso devido às inúmeras vantagens que apresentam. A geometria fractal aliada ao bom desempenho e comodidade das estruturas planares são uma excelente combinação para projetos e análise de estruturas cada vez menores e com características multibanda e banda larga. Nesse contexto as redes neurais artificiais (RNA) surgem como uma técnica bastante robusta e eficiente computacionalmente na resolução de problemas com tratamento matemático difícil de ser resolvido. O objetivo desse trabalho consiste em uma investigação a respeito do comportamento do parâmetro *inset-fed* no casamento de impedância de antenas *patches* quase-fractal em que uma modelagem dessas antenas é realizada utilizando-se uma rede de perceptrons de múltiplas camadas (MLP) com a finalidade de localizar as bandas de frequência operacionais para diferentes configurações geométricas. As antenas são excitadas por linha de alimentação com reentrâncias visando um casamento de impedância. O projeto das antenas foram auxiliados através de simulações com o *software Ansoft DesignerTM*, que implementa o método dos momentos (MoM). A partir destas simulações, vários protótipos de antenas quase-fractais (nível 1 e 2) utilizando a curva de Koch foram construídos. Com o intuito de validar os resultados obtidos pela rede neural, foram feitas comparações entre a saída da rede e os resultados medidos e simulados em *software* na região de interesse investigada.

Palavras-chave: antena quase-fractal, geometria fractal, redes neurais artificiais, antenas de microfita

1 INTRODUÇÃO

Os sistemas de comunicação sem fio (*wireless*) vêm experimentando um crescimento considerável em inúmeras aplicações nos últimos anos, exercendo um papel cada vez mais importante no cotidiano das pessoas e de grandes empresas nos mais diferentes serviços e setores de telecomunicações pelo mundo. Estes sistemas necessitam de dispositivos portáteis, com baixo perfil e tem despertado bastante interesse dos pesquisadores. Não restam dúvida que a miniaturização e a operação em várias faixas de frequências (multibanda) são requisitos desejáveis aos aparelhos de comunicação modernos. Neste mercado competitivo, o surgimento de novas tecnologias sem fio resulta em demandas crescentes por antenas com baixo custo, compactas/multibanda, que permitam, por exemplo, a união de diferentes tecnologias sem fio em um único dispositivo portátil, como é o caso das antenas planares em microfita (OLIVEIRA, 2009). A construção de antenas com estas características, possivelmente sem perdas de desempenho, ainda é um desafio aos pesquisadores da área. Este artigo consiste em uma investigação numérica e experimental, consistindo do projeto, simulação computacional, construção e medição de duas estruturas *patches* quase-fractal de nível 1 e nível 2 denominadas de KR1 e KR2 respectivamente por meio da utilização da curva de fractal de Koch (MANDELROT, 1983) (MANDELROT, 1991). Também é realizada uma modelagem neural dos parâmetros eletromagnéticos associados a essas estruturas. Devido a grande complexidade de análise dessas estruturas, técnicas de onda completa são normalmente utilizadas, a exemplo das diferenças finitas no

domínio do tempo (FDTD). As redes neurais artificiais são constituídas de processadores de informação distribuídos paralelamente ao longo da arquitetura rede utilizada (HAYKIN, 2001). Elas surgem como uma técnica alternativa em relação aos métodos de onda completa que necessitam de um rigor matemático mais complexo. Dessa forma algumas características tais como: fácil adaptabilidade, generalização e rápida convergência são características que elevam o interesse dessa técnica na análise dos mais diversos dispositivos de microondas, a exemplo das antenas *patches* em microfita. A seção 2 apresenta um estudo a respeito de redes neurais artificiais e a arquitetura de rede utilizada neste trabalho. O algoritmo de treinamento utilizado na modelagem das antenas analisadas é descrito na seção 3. A estrutura das antenas analisadas é descrita na seção 4. A seção 5 mostra os resultados numéricos, experimentais e a saída da rede para as antenas investigadas. Por fim a seção 6 apresenta as conclusões finais desse trabalho.

2 REDES NEURAIS ARTIFICIAIS

Uma rede neural (RNA) é uma máquina que é projetada para modelar a maneira como o cérebro realiza uma tarefa particular ou função de interesse. Para alcançarem bom desempenho, as redes neurais empregam uma interligação maciça de processadores, também chamado de neurônio (HAYKIN, 2001). A Figura 1 ilustra o modelo de um neurônio artificial.

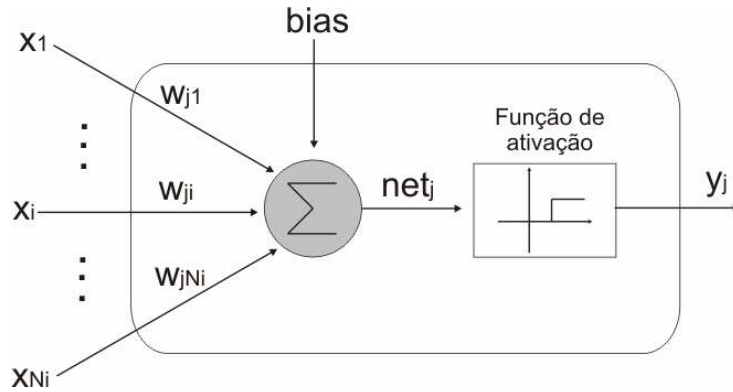


Figura 1 – Modelo de um neurônio artificial

Matematicamente um neurônio j de uma RNA com N_i entradas é expresso por

$$net_j = \sum_{i=1}^{N_i} x_i w_{ji} + b \quad [\text{Eq. 01}]$$

$$y_j = \phi(net_j) \quad [\text{Eq. 02}]$$

Em que, x_1, x_2, \dots, x_{N_i} são os sinais de entrada; w_1, w_2, \dots, w_{ji} são os pesos sináptico entre o neurônio i e neurônio j ; b é um valor de polarização (bias); net_j é o potencial de ativação; $\phi(\cdot)$ é a função de ativação, e y_j é o sinal de saída do neurônio. Várias são as funções de ativação que podem ser empregadas na formulação de um neurônio. De uma maneira geral a função de ativação mais comumente utilizada é a função sigmóide, dado pela [Eq. 03].

$$\phi(net_j) = \frac{1}{1 + \exp(-net_j)} \quad [\text{Eq. 03}]$$

Uma arquitetura de rede perceptron de múltiplas camadas (MLP) é uma estrutura com grande capacidade computacional. Isto em virtude de possuir mais uma camada intermediária de neurônios ocultos, em que cada neurônio da rede possui uma função de ativação não-linear, onde normalmente utiliza-se a função sigmóide. Dessa forma essa estrutura é apta a resolver problemas não-linearmente separáveis, fazendo-se uso de uma ou mais camada intermediária de neurônios ocultos (HAYKIN, 2001). A Figura 2 ilustra uma arquitetura de rede MLP, sendo uma camada de entrada (nós de fonte), duas camadas intermediária de neurônios ocultos e uma camada de saída com um neurônio. Este foi o modelo de rede neural utilizado neste trabalho para a modelagem das antenas analisadas.




Figura 2 – Rede MLP com quatro camadas de neurônios

3 ALGORITMO DE TREINAMENTO

A mais importante propriedade de uma rede neural artificial é sua capacidade de aprendizado. Uma rede neural aprende através de um processo iterativo de ajustes aplicados aos seus pesos sinápticos e limiares, o qual pode ser expresso na forma de um algoritmo computacional. Uma definição interessante de aprendizado é dado por Haykin et al. (2001), da seguinte forma: “O aprendizado é um processo pelo qual os parâmetros livres de uma rede neural são adaptados através de um processo de estímulo pelo ambiente no qual a rede está inserida”.

3.1 Algoritmo de Retropropagação do erro (*Backpropagation*)

O algoritmo *backpropagation* é um método de primeira ordem, isto é, ele leva em conta apenas a primeira derivada da função custo (E), baseado na técnica de aprendizagem supervisionada, em que é necessário o conhecimento prévio das relações de entrada/saída de forma a ser utilizada no treinamento da rede e é baseado na regra do gradiente descendente, onde os pesos são adaptados da seguinte maneira.

$$\Delta w = \eta \frac{\partial E(n)}{\partial w(n)} \quad [\text{Eq. 04}]$$

Em que, E representa a função custo e η é a taxa de aprendizado.

3.2 Algoritmo RPROP (*Resilient Backpropagation*)

Criado visando suprir as limitações do algoritmo *backpropagation*, o algoritmo RPROP é uma das variações do *backpropagation* e caracteriza-se por uma taxa de aprendizagem adaptativa e individual para cada peso da rede. Este processo elimina a influência prejudicial das derivadas parciais do vetor gradiente na otimização dos pesos em uma rede MLP diretamente da informação do gradiente local (RIEDMILLER, 1993). O resultado desse efeito é que o esforço de adaptação não é influenciado pelo comportamento imprevisível do gradiente. Portanto, apenas o sinal do gradiente é considerado no ajuste dos parâmetros livres. A atualização no RPROP é realizada por época de treinamento, cada peso da rede é atualizado de forma individual, [Eq. 05] - [Eq. 07].

$$w_{ji}^{(t+1)} = w_{ji}^{(t)} + \Delta w_{ji}^{(t)} \quad [\text{Eq. 05}]$$

$$\Delta w_{ji}^{(t)} = \begin{cases} -\Delta_{ji}^{(t)} & \text{se } \frac{\partial E^t}{\partial w_{ji}^{(t)}} > 0 \\ +\Delta_{ji}^{(t)} & \text{se } \frac{\partial E^t}{\partial w_{ji}^{(t)}} < 0 \\ 0 & \text{caso contrário} \end{cases} \quad [\text{Eq. 06}]$$

$$\Delta_{ji}^{(t)} = \begin{cases} \eta^+ * \Delta_{ji}^{(t-1)} & \text{se } \frac{\partial E^{(t-1)}}{\partial w_{ji}} * \frac{\partial E}{\partial w_{ji}} > 0 \\ \eta^+ * \Delta_{ji}^{(t-1)} & \text{se } \frac{\partial E^{(t-1)}}{\partial w_{ji}} * \frac{\partial E}{\partial w_{ji}} < 0 \\ 0 & \text{caso contrário} \end{cases} \quad [\text{Eq. 07}]$$

4 ESTRUTURA DAS ANTENAS DE MICROFITA COM PATCH QUASE-FRACTAL

Para o projeto das antenas quase-fractais, partiu-se inicialmente do projeto de uma antena *patch* retangular convencional (A0), descrita em Oliveira et al. (2008), baseado no modelo TLM descrito em Balanis et al (1997) em que os parâmetros geométricos (L, W) comprimento e largura do *patch* radiante foram calculadas através das expressões analíticas encontradas na literatura especializada (BALANIS, 1997). A curva fractal de Koch com fator de interação de 1/3 em L e 1/4 em W foram aplicadas as margens radiante e não-radiante em apenas três dos contornos da antena A0 e KR1 (Koch retangular nível 1) e nos quatro lados para o projeto da antena quase-fractal Koch retangular nível 2 (KR2), em que o quarto lado foi utilizado para alimentação e casamento de impedância. A geometria das antenas propostas é mostrada na Figura 3. Ela consiste de um elemento *patch* fractal montado sobre uma camada dielétrica isotrópica depositada sobre um plano de terra. Um cabo coaxial de 50 Ω conecta-se à linha de alimentação do elemento *patch* através de um conector SMA. Reentrâncias (*inset-fed* - y_o) no final da linha alimentação são inseridas para que possamos obter um melhor casamento de impedância entre a linha de alimentação e o *patch* radiante (RAMESH, 2003). O substrato utilizado foi um fibra de vidro (FR4) com 1,5 mm de espessura e uma permissividade elétrica relativa igual a 4,4.




Figura 3 – (a) Antena quase-fractal KR1; (b) Antena quase-fractal KR2

5 RESULTADOS NUMÉRICOS E EXPERIMENTAIS

Na análise das antenas por redes neurais, optou-se por utilizar resultados medidos com um Analisador de Redes Vetorial modelo HP8757D ao invés dos resultados simulados no *software Ansoft DesignerTM* que implementa o método dos momentos (MoM). Os resultados simulados foram utilizados para comparação e validação dos modelos neurais propostos. O objetivo do modelamento desenvolvido é verificar a influência de alguns parâmetros da estrutura no comportamento da resposta final e a partir desses dados treinar uma rede neural para que essa seja capaz de prever a resposta da estrutura em função da mudança do parâmetro estudado. Neste caso será o parâmetro *inset-fed* (y_o), dentro de uma determinada faixa de frequência de interesse.

5.1 Modelagem da antena KR1

Para a modelagem dessa antena foram construídos quatro protótipos de antenas com as características elétricas especificadas na Tabela 1. Para cada antena foram separados 100 valores medidos referentes ao parâmetro de espalhamento $|S_{11}|$ (perda de retorno) em função da frequência. Esses valores caracterizarão o conjunto de treinamento da rede. Para o treinamento da rede, optou-se por utilizar uma rede MLP com dois nós de entrada, referente a frequência de operação e ao parâmetro *inset-fed*, duas camadas ocultas com 30 neurônios cada e um neurônio de saída referente ao parâmetro $|S_{11}|$ a ser modelado. Na fase de treinamento foi utilizado o algoritmo RPROP para os seguintes dados referente ao conjunto de treinamento da antena KR1 com diferentes *inset-fed*, tal como: $y_o = [7,2; 7,5 \text{ e } 8,15]$, conforme ilustra a Figura 4.

Tabela 1 – Parâmetros elétricos das antenas *patches* quase-fractais KR1 e KR2

Comprimento do <i>Patch</i>	$L = 29,094 \text{ mm}$
Largura do <i>Patch</i>	$W = 37,2343 \text{ mm}$
Comprimento do <i>inset-fed</i> para KR1	$y_o = [7,2; 7,5; 8,4 \text{ e } 8,15] \text{ mm}$
Comprimento do <i>inset-fed</i> para KR2	$y_o = [8,2; 8,45; 8,71 \text{ e } 9,0] \text{ mm}$
Comprimento da linha de alimentação	$L_o = 8,3803 \text{ mm}$
Espessura do substrato dielétrico	$h = 1,50 \text{ mm}$
Constante dielétrica	$\epsilon_r = 4,4$
Largura da linha de alimentação	$W_o = 2,8707 \text{ mm}$
Largura do <i>inset-fed</i>	$x_o = 2,8707 \text{ mm}$

Pela Figura 4 se observa que a principal influência na variação do parâmetro y_o é com relação a perda de retorno da estrutura analisada e dessa forma é preservada a frequência de ressonância em torno de 1,79 GHz. Para um conjunto de valores que não foi utilizado durante a fase de treinamento, a rede apresenta o resultado mostrado na Figura 5, nesse caso o valor de $y_o = 7,84 \text{ mm}$. Observa-se uma excelente concordância entre a resposta fornecida pela rede neural em comparação com o resultado medido e simulado, validando dessa forma o modelo neural utilizado.




Figura 4 – Conjunto de treinamento utilizado na modelagem da antena KR1

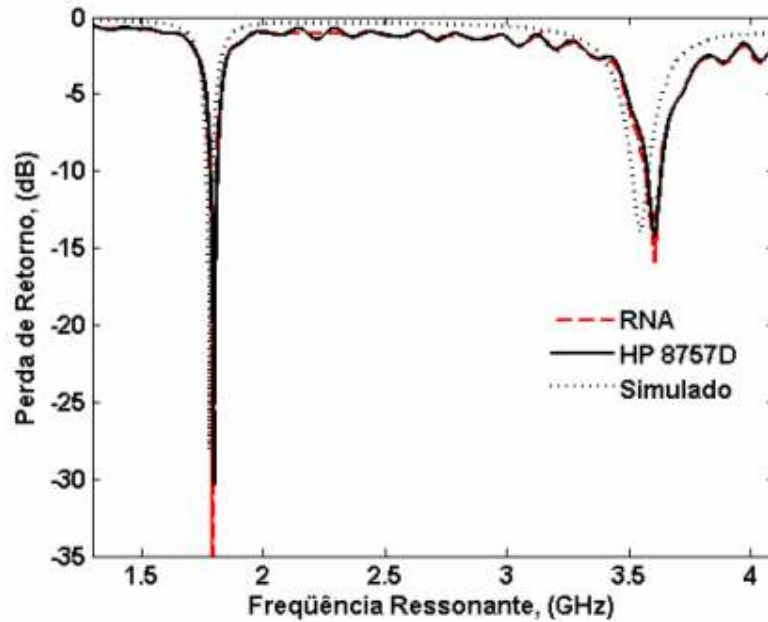


Figura 5 – Resposta da rede a um padrão não utilizado no treinamento ($y_o = 7,84\text{ mm}$)

5.2 Modelagem da antena KR2

Para a modelagem dessa antena novamente foram construídos quatro protótipos de antenas com as mesmas características elétricas especificadas na Tabela 1, para diferentes comprimentos de *inset-fed*. Para cada antena foram separados 100 valores medidos como conjunto de treinamento referentes ao parâmetro de espalhamento $|S_{11}|$ em função da frequência. Para o treinamento dessa estrutura, novamente utilizou-se uma rede MLP treinada com o algoritmo RPROP com duas camadas ocultas com 40 neurônios cada, em que foi utilizado os dados da antena referente à $y_o = [8,2; 8,45 \text{ e } 9,0]$, conforme ilustra a Figura 6. Pela Figura 6, novamente se observa que a principal influência na variação do parâmetro y_o é com relação a perda de retorno da estrutura analisada, em que se observa também uma mínima discordância na segunda ressonância, onde a primeira se manteve preservada em torno de 1,45 GHz. Após a fase de treinamento, a resposta da rede a um padrão não utilizado no treinamento é ilustrada na Figura 7. Novamente se observa uma boa

concordância entre os resultados e uma melhor concordância da rede neural com o resultado medido em relação ao resultado simulado, validando dessa forma o modelo neural proposto.

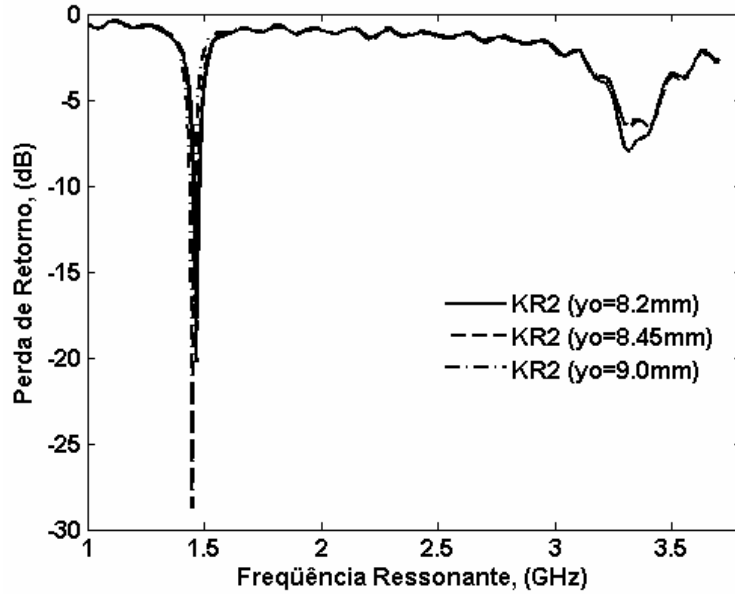


Figura 6 – Conjunto de treinamento utilizado na modelagem da antena KR2

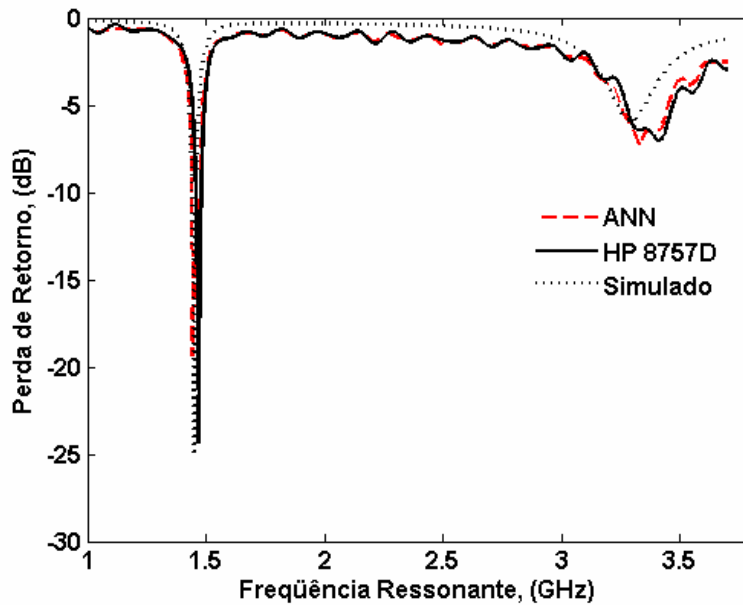


Figura 7 – Resposta da rede a um padrão não utilizado no treinamento ($y_o = 7,84$ mm)

6 CONCLUSÃO

Este trabalho reuniu a tecnologia em microfita associada à geometria fractal para o projeto e modelagem de antenas quase-fractais (KR1 e KR2) utilizando redes neurais artificiais. As antenas investigadas tiveram seu parâmetro de *inset-fed* (y_o) modelados por uma rede de perceptrons de múltiplas camadas treinada com o algoritmo RPROP. Uma vez treinada adequadamente, a arquitetura de rede utilizada possibilitou uma boa capacidade de generalização dentro da faixa de frequência de interesse, em que os resultados medidos e simulados concordam bem com a saída do modelo neural proposto para a modelagem do parâmetro *inset-fed*. Os resultados obtidos mostram que a metodologia por meio de redes neurais artificiais pode muito bem ser empregada na análise e modelagem de dispositivos de micro-ondas. Trabalhos futuros poderão incluir algoritmos genéticos (GA) no projeto, análise e otimização de antenas de microfita.

REFERÊNCIAS

RIEDMILLER, M. BRAUN, H. **A Direct Adaptive Method for Faster Backpropagation Learning: The RPROP Algorithm.** In Proceedings of the IEEE International Conference on Neural Networks, VOL. 1, 1993. 586-591 p.

RAMESH, M. KB, Y. **Design Formula for Inset Fed Microstrip Patch Antenna.** Journal of Microwaves and Optoelectronics, VOL. 3, 2003. 5-10 p.

HAYKIN, S. **Redes Neurais – Princípios e Prática.** Bookman, 2001.

BALANIS, C. A. **Antenna theory-analysis and design.** 2 ed. New York; John Wiley and Sons, Inc., 1997.

MANDELBROT, B. B. **Objetos Fractais: forma, acaso e dimensão.** Lisboa; Gradiva Publicações, 1991.

OLIVEIRA, E. E. C. SILVA, P. H. F. CAMPOS, A. L. P. S. **Overall Size Antenna Reduction Using Fractal Elements.** Microwave and Optical Technology Letters, VOL. 51, 2009. 671-675 p.

MANDELBROT, B. B. **The Fractal Geometry of Nature.** New York; W. H. Freeman, 1983.