

## MODELAGEM NÃO LINEAR DE DISPOSITIVOS DE MICROONDAS E ÓPTICOS ATRAVÉS DA REDE NEURAL MODULAR RBF/MLP

Márcio Galdino Passos e Paulo Henrique da Fonseca Silva  
CEFET-PB/GTEMA – Av. 1º de Maio, 720 Jaguaribe  
CEP: 58015-430 – João Pessoa, PB, Brasil  
E-mail: henrique@cefetpb.edu.br

### RESUMO

Este artigo apresenta uma nova rede neural modular RBF/MLP, constituída de redes RBFs (*Radial Basis Functions*) especialistas conectadas a redes MLPs (*Multilayer Perceptrons*) de saída. Esta configuração foi assim concebida tendo em vista as características de aproximação local e global da redes RBF e MLP, respectivamente. O treinamento das redes neurais é realizado através do eficiente algoritmo Rprop (*Resilient Backpropagation*). As propriedades de aprendizado, aproximação e generalização da rede modular são demonstradas a partir do desenvolvimento de modelos neurais para dispositivos nas faixas de microondas e óptica. Estes modelos não lineares implementados através de uma configuração modular (com duas redes RBFs especialistas e uma rede de MLP de saída) são usados para análise de características físicas e elétricas de dispositivos passivos de microondas com estruturas PBG (*Photonic Band Gap*), bem como, de amplificadores ópticos em semicondutores de arseneto de gálio (GaAs). Com uma redução considerável do custo computacional, em comparação com modelos físicos existentes, a configuração modular RBF/MLP é capaz de aprender com consistência e generalizar para novos valores, em regiões de interesse onde se tem pouco ou nenhum conhecimento sobre o comportamento dos dispositivos estudados. Os resultados obtidos através dos modelos neurais RBF/MLP propostos apresentaram excelente concordância com os resultados (medidos ou simulados) estabelecidos na literatura especializada. A eficiência computacional e a precisão, associadas à flexibilidade são algumas características dos modelos neurais que permitem melhorar o desempenho de ferramentas de CAD (*Computer Aided Design*) contribuindo tanto para análise quanto para o projeto de novos dispositivos.

**PALAVRAS-CHAVE:** redes neurais; dispositivos de microondas; dispositivos ópticos; modelos não lineares.

## 1. INTRODUÇÃO

O uso constante de ferramentas computacionais para o desenvolvimento de projetos de dispositivos, para sistemas de telecomunicações, tem gerado um novo paradigma de modelagem e simulação. As ferramentas de CAD (*Computer Aided Design*) para aplicações nas faixas de RF (*radio frequency*), microondas, ondas milimétricas e óptica receberam um maior destaque a partir da década de 90. Algumas destas ferramentas incluem: a modelagem precisa de dispositivos passivos e ativos, a simulação computacional-eletromagnética e a análise de circuitos não lineares utilizando balanço harmônico e aproximações no domínio do tempo (Patnaik e Misha, 2000).

Muitos simuladores eletromagnéticos voltados para estruturas em altas-frequências já estão disponíveis, tornando o CAD para a elaboração de circuitos e dispositivos de RF/microondas e ópticos o estado da arte na área. Isto se deve, em parte, à grande demanda do mercado e da indústria por tais ferramentas de *software*. Por exemplo, os dispositivos ópticos possuem características desejáveis em sistemas de telecomunicações, tais como: banda larga com pouca atenuação e imunidade contra interferências externas, leveza, tamanho reduzido, baixo custo (Dunlop, 1994). Já os circuitos de RF/microondas avançaram com a tecnologia planar, a confecção de circuitos híbridos MMIC (*Monolithic Microwave Integrated Circuits*) para aplicações em arranjos de fase e sistemas sem fio (Gupta e Hall, 2000).

A análise estatística e a otimização baseada em modelos físicos rigorosos - eletromagnéticos - de componentes ativos e passivos pode ser uma boa solução inicial. No entanto, a complexidade física incorporada em tais modelos rigorosos torna excessivo o tempo/custo da simulação computacional, que geralmente necessita de uma poderosa plataforma de *hardware*. Alternativamente, os modelos empíricos são usados em alguns simuladores, mas, estes apresentam limitações na faixa de aplicação, bem como deixam a desejar quanto a precisão (Milovanovic et al., 2003). Assim, a fim de se preencher a lacuna existente entre os modelos físicos/numéricos e empíricos/análitos a tecnologia das redes neurais artificiais (ANNs – *Artificial Neural Networks*) tem sido introduzida pela comunidade científica para a elaboração de modelos não lineares de dispositivos e circuitos.

A técnica EM-ANN (*Electromagnetic - Artificial Neural Network*) (Zhang e Gupta, 2000) tem sido utilizada na modelagem de uma variedade de componentes ativos e passivos de microondas, cujo comportamento não linear pode ser considerado ‘suave’, por exemplo: transistores, descontinuidades em linhas de microfita, componentes passivos em guias de ondas coplanares, etc. Nesta técnica, uma rede neural simples, MLP ou RBF, é treinada diretamente através de dados eletromagnéticos precisos, que representam o modelo não linear de funcionamento do componente analisado.

Contudo, a técnica EM-ANN apresenta algumas desvantagens que restringem a sua aplicação. Por exemplo, como toda a informação é extraída pela ANN dos dados de treinamento, uma quantidade maior de dados é necessária para manter a precisão do modelo. O aumento da quantidade de dados de treinamento em um problema de aprendizagem complexo pode sobrecarregar uma rede neural, dificultando seu dimensionamento e treinamento. Por outro lado, mesmo com uma quantidade suficiente de dados de treinamento, a confiabilidade dos modelos neurais resultantes, quando usados para extrapolação e generalização, não é garantida, e, em muitos casos, é muito pobre, (Zhang e Gupta, 2000).

A maioria dos problemas encontrados no uso da técnica EM-ANN podem ser contornados através da combinação de redes neurais em estruturas modulares, que aumentam a eficiência do treinamento e a precisão do modelo neural resultante (Hashem and Schmeiser, 1995) (Lendaris et. al., 1997). Este conceito é fundamentado no princípio ‘dividir e conquistar’, no qual um problema complexo de modelagem não linear é dividido em problemas menores, que são solucionados entre as redes neurais da estrutura modular.

Neste artigo, uma estrutura modular RBF/MLP é proposta através da combinação de duas redes RBF especialistas e de uma rede MLP de saída, com aplicações à modelagem de dispositivos de microondas/ópticos. A seção 2 apresenta um estudo revisional das redes RBF e MLP, a descrição do algoritmo de treinamento *Resilient BackPropagation*, bem como a elaboração de modelos através da estrutura modular RBF/MLP. As aplicações destes modelos neurais são descritas na seção 3 para uma linha de microfita com material PBG anisotrópico no plano terra e para um amplificador óptico baseado em GaAs. Também são incluídos estudos comparativos entre os resultados obtidos através dos modelos RBF/MLP e resultados medidos ou simulados apresentados na literatura. A seção 4 reúne as conclusões deste trabalho.

## 2. REDES NEURAIS ARTIFICIAIS

### 2.1. Redes *Perceptrons* de Múltiplas Camadas

As redes MLPs têm como unidade básica o neurônio artificial, ou *perceptron*, ilustrado na Fig. 1. Estas unidades são distribuídas em camadas onde cada uma está conectada a todas unidades da camada anterior. Neste modelo, é calculado o produto interno das entradas aplicadas,  $x_i$ , com os pesos  $w_{ji}$  e também é incorporada uma polarização,  $x_0$ , aplicada externamente. O efeito desta polarização é importante quando a soma ponderada dos neurônios da camada anterior for igual a zero. A soma resultante, considerada como nível de atividade interna ou potencial de ativação,  $net_j$ , é aplicada então a uma função de ativação,  $\varphi(net_j)$ , que pode ser a saída final da rede, ou as entradas de outros *perceptrons* da camada seguinte (Passos, 2006). A partir destas características, a Fig. 2 ilustra a configuração de uma rede MLP com uma camada oculta.




Fig. 1: Modelo do neurônio artificial (*perceptron*) utilizado nas redes MLPs.




Fig. 2: Configuração de uma rede MLP com uma camada de neurônios ocultos e um neurônio na camada de saída.

Conforme a notação estabelecida na Fig. 2, tem-se (resultam) as expressões matemáticas para a computação no sentido direto realizada por uma rede MLP:

$$z_k(n) = \varphi_2(net_k(n)) = net_k(n) = \sum_{j=0}^{Nh} v_{kj}(n) y_j(n), \quad k = 1 \quad (1)$$

$$y_j(n) = \varphi_1(net_j(n)) = \frac{1}{1 + \exp(-net_j(n))}, \quad j = 1, 2, \dots, Nh \quad (2)$$

$$net_j(n) = \sum_{i=0}^{Ne} w_{ji}(n) x_i(n), \quad j = 1, 2, \dots, Nh \quad (3)$$

Na etapa de treinamento de uma rede neural, o objetivo principal a ser alcançado é a minimização do erro entre a resposta da rede,  $z(n)$  e o exemplo de treinamento apresentado,  $d(n)$ , conforme estabelece a Eq. (4). Para evitar que valores positivos de erro anulem valores negativos, em geral, toma-se o erro quadrático, Eq. (5).

$$e(n) = d(n) - z(n) \quad (4)$$

$$E(n) = \frac{1}{2} [e(n)]^2 \quad (5)$$

Para o ajuste dos parâmetros livres da rede, pode-se utilizar métodos de minimização de funções e aplicá-los em (5) com relação aos pesos da rede. A avaliação do treinamento é feita através da observação do MSE (*Mean Square Error*) calculado como sendo o erro médio de todos os exemplos de treinamento utilizados em uma época. Neste trabalho, em particular, foi utilizado o método do gradiente, para a minimização do erro, resultando nas seguintes equações recursivas de ajuste dos pesos na etapa de treinamento da rede MLP:

$$v_{kj}(n+1) = v_{kj}(n) + \eta e(n) y_j(n) \quad (6)$$

$$w_{ji}(n+1) = w_{ji}(n) + \eta e(n) v_{kj}(n) y_j(n) (1 - y_j(n)) x_i(n) \quad (7)$$

em que  $\eta$  é a taxa de aprendizado inerente ao método do gradiente. Uma má escolha de  $\eta$  pode resultar numa lentidão excessiva no treinamento. Riedmiller e Braun apresentaram uma solução para este problema através do algoritmo de treinamento *Resilient BackPropagation* ou *Rprop* (Riedmiller e Braun, 1993). Neste método, a taxa de aprendizado é adaptativa, individual para cada parâmetro livre e a influência indesejável da magnitude das derivadas, devido ao método do gradiente, é ignorado. O ajuste dos pesos através do *Rprop* é do tipo batch (em lote) ou por época de treinamento. Cada peso do MLP ( $w_{ji}$  e  $v_{kj}$ ) é ajustado através das Eqs. (8)-(10).

$$w_{ji}^{(t+1)} = w_{ji}^{(t)} + \Delta w_{ji}^{(t)} \quad (8)$$

$$\Delta w_{ji}^{(t)} = \begin{cases} -\Delta_{ji}^{(t)}, & \text{se } \frac{\partial E^{(t)}}{\partial w_{ji}} > 0 \\ +\Delta_{ji}^{(t)}, & \text{se } \frac{\partial E^{(t)}}{\partial w_{ji}} < 0 \\ 0, & \text{demais casos} \end{cases} \quad (9)$$

$$\Delta_{ji}^{(t)} = \begin{cases} \eta^+ * \Delta_{ji}^{(t-1)}, & \text{se } \frac{\partial E^{(t)}}{\partial w_{ji}} * \frac{\partial E^{(t-1)}}{\partial w_{ji}} > 0 \\ \eta^- * \Delta_{ji}^{(t)}, & \text{se } \frac{\partial E^{(t)}}{\partial w_{ji}} * \frac{\partial E^{(t-1)}}{\partial w_{ji}} < 0 \\ \Delta_{ji}^{(t)}, & \text{demais casos} \end{cases} \quad (10)$$

Em que,  $E$  é o erro quadrático de uma época de treinamento  $t$  e  $\eta^+ = 1,2$  e  $\eta^- = 0,5$  são constantes (Riedmiller e Braun, 1993). Este algoritmo foi utilizado em todos os modelos apresentados neste trabalho.

## 2.2. Redes de Funções de Base Radial

A rede RBF apresenta uma configuração semelhante à apresentada na Fig. 2 tendo como diferenças principais a forma do cálculo do potencial de ativação da camada oculta, bem como a própria função de ativação. Para a propagação dos sinais do sentido direto de uma rede RBF, seguindo a notação da Fig. 2, obtém-se as seguintes expressões:

$$z_k(n) = \varphi_2(net_k(n)) = net_k(n) = \sum_{j=0}^{Nh} v_{kj}(n)y_j(n), \quad k = 1 \quad (11)$$

$$y_j(n) = \varphi_1(net_j(n)) = \exp\left(-\frac{1}{\sigma_j^2(n)}net_j(n)\right), \quad j = 1, 2, \dots, Nh \quad (12)$$

$$net_j(n) = \|x(n) - w_j(n)\| = \sqrt{(x(n) - w_j(n))' \cdot (x(n) - w_j(n))}, \quad j = 1, 2, \dots, Nh \quad (13)$$

em que  $w_j$  representa o centro da função de base radial associada a cada neurônio da camada oculta e  $\sigma^2$  representa o espalhamento ou largura das funções de base radial. Através do método do gradiente, obtém-se as expressões recursivas para o ajuste dos parâmetros livres de uma rede RBF, Eqs (14)-(16).

$$v_{kj}(n+1) = v_{kj}(n) + \eta e(n)y_j(n) \quad (14)$$

$$w_j(n+1) = w_j(n) + \eta 2e(n)v_{kj}(n) \frac{y_j(n)}{\sigma_j^2(n)} [(x(n) - w_j(n))] \quad (15)$$

$$\sigma_j^2(n+1) = \sigma_j^2(n) + \eta e(n)v_{kj}(n)y_j(n) \left( \frac{\|x(n) - w_j(n)\|}{(\sigma_j^2(n))^2} \right) \quad (16)$$

Do mesmo modo como na rede MLP, o algoritmo *Rprop* foi aplicado neste trabalho para o treinamento das redes RBFs. As Eqs. (8)-(10) foram adaptadas para o ajuste dos pesos da camada de saída, dos centros e dos espalhamentos das funções de base radial.

### 2.3. Rede Modular RBF/MLP

Como já apresentado na Seção 1, alguns problemas de modelagem eletromagnética, devido a sua complexidade, não podem ser realizados com apenas uma rede neural. Neste trabalho, para a obtenção dos resultados, foi empregada uma estrutura modular com duas camadas de redes neurais. A configuração utilizada é composta por três redes: duas especialistas do tipo RBF e uma rede de saída do tipo MLP, conforme ilustrado na Fig. 3(a). Os parâmetros valor inicial, valor final e variável estão relacionados com a região de interesse definida pelos parâmetros de entrada do modelo, Fig. 3(b). Esta organização das redes é de suma importância devido às características de aprendizado de cada rede utilizada para mapeamentos entrada/saída não lineares: as RBFs realizam aproximações locais enquanto as redes MLPs realizam aproximações globais (Passos et. al., 2006 a,b).

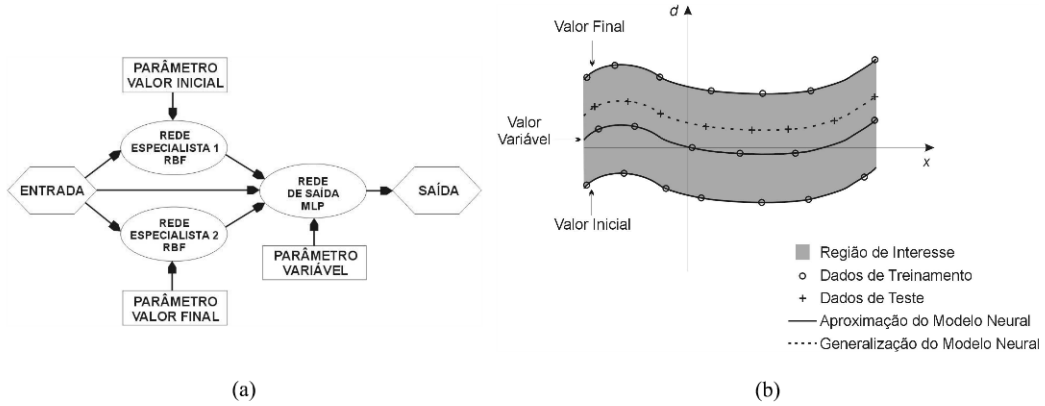


Fig. 3: (a) Rede modular RBF/MLP e (b) Região de interesse a ser modelada através da rede modular.

A divisão dos dados de treinamento é outra característica que contribui para a eficiência do treinamento das redes da estrutura RBF/MLP. Enquanto a rede especialista 1 é treinada apenas com a curva referente ao parâmetro valor inicial, a rede especialista 2 é treinada com a curva correspondente ao parâmetro valor final; por sua vez, a rede de saída é treinada a partir de todo o conjunto de dados de treinamento, com as respostas das redes especialistas pré-treinadas servindo como entradas adicionais. As comparações entre modelos neurais desenvolvidos através de redes neurais MLP e RBF individuais e através de configurações modulares RBF/MLP, destacam-se algumas vantagens destas últimas: treinamento mais eficiente, maior consistência do processo de aprendizado, bem como maior capacidade de aproximação/generalização (Passos, 2006).

### 3. APLICAÇÕES

#### 3.1. Linha de Microfita com Material PBG Planar Anisotrópico

Uma linha de microfita é uma linha de transmissão planar composta de uma fita condutora e de uma base metálica (ou plano terra), separadas por um substrato dielétrico. A estrutura básica de uma linha de microfita é mostrada na Fig. 4(a). O material PBG planar anisotrópico é inserido no plano terra de uma linha de microfita e é composto de fendas de larguras alternadas, como apresentado na Fig. 4(b). Este tipo de material PBG possui um padrão bi-dimensional (2-D) formado por células com  $180^\circ$  de simetria. Quando a linha de microfita está localizada na direção  $z$ , a corrente induzida flui livremente através da estrutura e o sinal é transmitido, enquanto o sinal é rejeitado quando a linha está localizada na direção  $y$  (Caloz e Itoh, 2002).




Fig. 4: (a) Linha de microfita com material PBG anisotrópico no plano terra. (b) Plano terra da estrutura PBG anisotrópica com seus respectivos parâmetros.

Para os resultados apresentados neste artigo, considerou-se o período  $a = 1,524$  mm e o substrato utilizado foi o RT/Duroid com  $h = 0,635$  mm e  $\epsilon_r = 10,2$ . As dimensões totais do PBG foram,  $L_y \times L_z = a(N_y \times N_z) = 1,524(N_y \times N_z)$  mm, onde  $N_y$  e  $N_z$  são os números de células unitárias ao longo do eixo  $y$  e  $z$ , respectivamente. Neste caso particular,  $N_z$  é fixado em 7 e  $N_y$  é variado de 1 a 7 e a linha é colocada na direção AD.

No treinamento do modelo neural através da rede RBF/MLP, dois parâmetros de entrada são levados em consideração: a frequência de operação,  $f$ , e o número de células no eixo  $y$ ,  $N_y$ . Os valores medidos do parâmetro de espalhamento  $S_{21}$  são utilizados como as respostas desejadas do modelo. Os dados de treinamento foram obtidos através de medidas apresentadas por Caloz e Itoh (Caloz e Itoh, 2002). As informações referentes ao modelo elaborado estão contidas na Tab. 1.

Tab. 1: Informações referentes ao treinamento da rede modular RBF/MLP para a linha com PBG anisotrópico.

Rede Neural	Especialista 1	Especialista 2	Saída
	RBF	RBF	MLP
Parâmetro de entrada:	$N_y = 1$	$N_y = 7$	$N_y = [1 \ 7]$
# neurônios ocultos:	15	25	25
# exemplos de treinamento:	84	84	168
MSE final:	5,86E-5	7,42E-4	1,62E-4
# épocas de treinamento:	2000	1500	2000




Fig. 5: (a) Aproximação do modelo RBF/MLP para os valores de  $N_y = 1$  e  $N_y = 7$ . (b) Generalização do modelo RBF/MLP em comparação com os valores medidos para  $N_y = 2$ .

A Fig. 5(a) apresenta os resultados obtidos a partir da simulação com a rede RBF/MLP desenvolvida. Uma boa concordância entre as respostas deste modelo e os valores medidos foi verificada, com uma excelente capacidade de interpolação para os exemplos de treinamento. Apesar de ser um problema altamente não linear, uma boa generalização foi obtida entre 100 MHz – 18 GHz, como visto na Fig. 5(b). Neste caso o modelo RBF/MLP pode auxiliar no projeto desta linha de microfita PBG-GP, sendo utilizada para estimar o comportamento tanto na banda passante como na banda de rejeição.

### 3.2. Amplificador Óptico Baseado em GaAs

Uma das principais aplicações dos amplificadores ópticos é o seu uso em estações repetidoras. Os *links* extensos de comunicação por fibra exigem o uso de repetidores, caso contrário, o sinal chegaria ao ponto de recepção com um nível abaixo do limiar de recepção. Sem os amplificadores ópticos, os sinais em estações repetidas teriam que ser convertidos em sinais elétricos, restaurados, sincronizados e reajustados. Todo este processo é eliminado com o uso de tais amplificadores (Iizuka, 2002).

O coeficiente de ganho de um amplificador óptico ( $\gamma$ ), dentre outros parâmetros, é função do nível de energia onde ocorrerá o decaimento de fótons ( $h\nu$ ), bem como da concentração de portadores injetados ( $\Delta n$ ) nas bandas de valência e de condução (Passos, 2006). O coeficiente de ganho de um amplificador óptico baseado em GaAs foi modelado para os valores de  $\Delta n = [1,2 \ 1,4 \ 1,6 \ 1,8 \ 2,0] \times 10^{18} \text{ cm}^{-3}$ . Este intervalo define a região de interesse considerada para este dispositivo com  $\Delta n$  representando o sinal de controle considerado. Para a obtenção de modelos mais eficientes para amplificadores ópticos, alternativos ao método tradicional de equações integrais, propôs-se a modelagem através da rede RBF/MLP. As principais características do amplificador modelado estão contidas na Tab. 2, (Saleh e Teich, 1991). A Tab. 3 apresenta as informações referentes ao treinamento das redes especialistas e de saída.

Tab. 2: Principais características do amplificador óptico de GaAs modelado.

Laser Semicondutor	GaAs
Temperatura	300 K
Energia de transição entre bandas	$E_g = 1,4 \text{ eV}$
Tempo de recombinação elétrons-lacunas	$\tau_r = 2 \text{ ns}$
Massa efetiva de elétrons da banda de condução	$m_c = 0,07 m_0$
Massa efetiva de elétrons da banda de valência	$m_v = 0,5 m_0$
Índice de refração do material	3,6

Tab. 3: Informações referentes ao treinamento da rede modular RBF/MLP para o amplificador óptico de GaAs.

Rede Neural	Especialista 1	Especialista 2	Saída
	RBF	RBF	MLP
Parâmetro de entrada ( $\Delta n$ ):	1,2	2	[1,2 1,8 2,0]
# neurônios ocultos:	4	4	15
# exemplos de treinamento:	17	35	83
MSE final:	2,39E-6	2,31E-4	5,11E-5
# épocas de treinamento:	5000	5000	5000

A Fig. 6 apresenta os resultados obtidos a partir da simulação com a rede RBF/MLP desenvolvida. Neste caso, com a concordância obtida entre as respostas deste modelo e do modelo físico, verifica-se a excelente capacidade de interpolação para os exemplos de treinamento. A capacidade de generalização da rede modular é apresentada na Fig. 7, com excelentes resultados obtidos para  $\Delta v = 1,4$  e  $\Delta v = 1,6 \times 10^{18} \text{ cm}^{-3}$ .

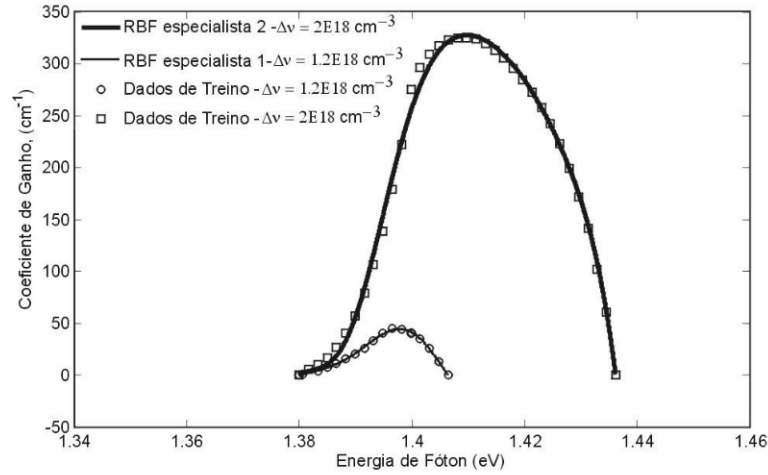


Fig. 6: Aproximação das redes especialistas do tipo RBF, para os valores de concentração de portadores injetados de  $1,2$  e  $2,0 \times 10^{18} \text{ cm}^{-3}$ .

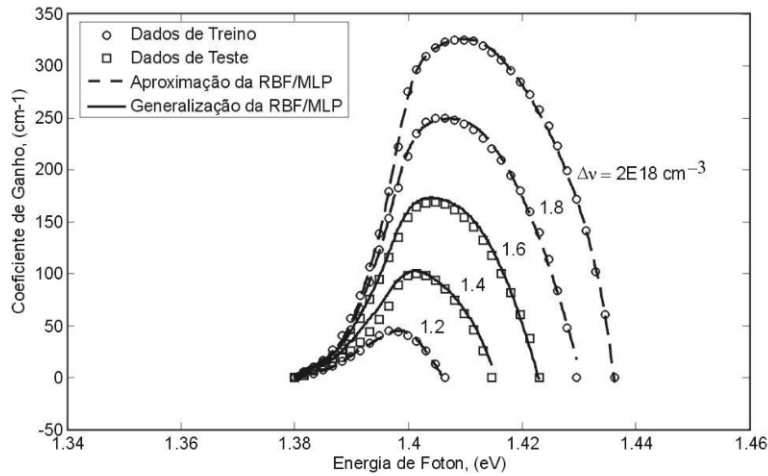


Fig. 7: Generalização da rede RBF/MLP para os valores de concentração de portadores injetados de  $1,4$  e  $1,6 \times 10^{18} \text{ cm}^{-3}$ .

A Fig. 8 compara os valores de pico do coeficiente de ganho estimados pela rede modular RBF/MLP com os valores obtidos pelo modelo físico (Saleh e Teich, 1991). Uma boa concordância é observada principalmente na região entre  $1,6$  e  $2 \times 10^{18} \text{ cm}^{-3}$ .

#### 4. CONCLUSÕES

Neste artigo, foi proposta uma estrutura modular de redes neurais RBF/MLP, treinadas através do eficiente algoritmo Rprop, e, desenvolvida especialmente para uso em aplicações de modelagem. Em particular, foram



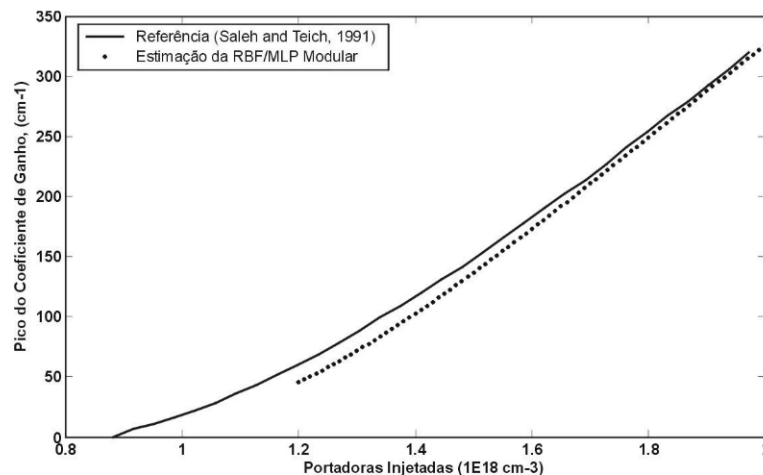


Fig. 8: Estimativa dos valores de pico do coeficiente de ganho do amplificador de GaAs através da rede RBF/MLP e valores de referência (Saleh e Teich, 1991).

abordados uma linha de microfita com plano terra PBG anisotrópico e um amplificador óptico baseado em material semiconductor de GaAs.

Os módulos da estrutura RBF/MLP foram organizados para tirar vantagem das características de aproximação local e global apresentadas pelas redes neurais RBF e MLP, respectivamente. Este tipo de organização em conjunto com a divisão do problema de modelagem, facilita o treinamento das redes RBF especialistas e da rede MLP de saída desta estrutura modular. Os resultados de simulação dos modelos neurais implementados, indicam uma boa confiabilidade dos modelos desenvolvidos através da estrutura modular RBF/MLP, com maior capacidade de aprendizado e generalização. Além disso, a estrutura RBF/MLP, treinada diretamente a partir de dados medidos/simulados através da técnica EM-ANN, é bastante flexível, podendo ser aplicada como modelos, principalmente quando surgem novos componentes/tecnologias para circuitos de microondas e dispositivos ópticos.

## 5. REFERÊNCIAS BIBLIOGRÁFICAS

- Caloz, C. and Itoh, T., **Multilayer and Anisotropic Planar Compact PBG Structures for Microstrip Applications**. IEEE Transactions on Microwave Theory and Techniques, v. 50, n. 9, p.2206-2208, 2002.
- Dunlop, J. and Smith, D. G., **Telecommunications Engineering – Third Edition**. Chapman and Hall, London, p.440-460, 1994.
- Gupta, K. C. and Hall, P. S., **Analysis and Design of Integrated Circuit – Antenna Modules**. John Wiley and Sons, Inc., p.xi-xii, 2000.
- Iizuka, K., **Elements of Photonics**. John Wiley and Sons, Inc., 2002.
- Hashem, S. and Schmeiser, B., **Improving Model Accuracy Using Optimal Linear Combinations of Trained Neural Networks**. IEEE Transactions on Neural Networks, v. 6, p.792-794, 1995.
- Lendaris, G. G., Rest, A. and Misley, T. R., **Improving ANN generalization using a priori knowledge to pre-structure ANNs**. Proc. IEEE Intl. Conf. Neural Networks, Houston, TX, p.248-253, Jun. 1995.
- Milovanovic, B., Markovic, V., Marinkovic, Z. and Stankovic, Z., **Some Applications of Neural Networks in Microwave Modeling**. Journal of Automatic Control, University of Belgrade, v. 13, p.39-46, 2003.
- Passos, M. G., **Modelos de Dispositivos de Microondas e Ópticos através de Redes Neurais Artificiais de Alimentação Direta**. Dissertação de Mestrado, Universidade Federal do Rio Grande do Norte, 88 f., 2006.

Passos, M. G., Silva, P. H. da F. and Fernandes, H. C. C., **A RBF/MLP Modular Neural Network for Microwave Device Modeling**. International Journal of Computer Science and Network Security, v. 6., n. 5(A), p. 81-86, 2006.

-----, **Modelos de Dispositivos com PBG Através de Redes Neurais Modulares RBF/MLP**. Anais do 12º Simpósio Brasileiro de Microondas e Optoeletrônica e 7º Congresso Brasileiro de Eletromagnetismo, 2006.

Patnaik, A. and Misha, R. K., **ANN Techniques in Microwave Engineering**. IEEE Microwave Magazine, p.55-60, Mar. 2000.

Riedmiller, M. and Braun, H., **A Direct Adaptive Method for Faster Backpropagation Learning: The Rprop Algorithm**. IEEE Int. Conf. Neural Networks, v. 1., p. 586-591, 1993.

Saleh, B. E. A. and Teich, M. C., **Fundamentals of Photonics**. John Wiley and Sons, Inc., 1991.

Wang, F., Devabhaktuni, V. K., Xi, C. and Zhang, Q., **Neural Network Structures and Training Algorithms for RF and Microwave Applications**. Int. Journal of RF and Microwave CAE, John Wiley and Sons, Inc., v. 9, p.216-240, 1999.

Zhang, Q. J. and Gupta, K. C., **Neural Networks for RF and Microwave Design**. Artech House, Inc., Norwood, MA, 2000.