

A TECNOLOGIA DE REDES NEURAIIS COMO UMA FERRAMENTA NUMÉRICA ALTERNATIVA PARA A ÁREA DE ENGENHARIA

Paulo Henrique da Fonseca Silva e Márcio Galdino Passos
CEFET-PB/GTEMA – Av. 1º de Maio, 720 Jaguaribe
CEP: 58015-430 – João Pessoa, PB, Brasil
E-mail: henrique@cefetpb.edu.br

RESUMO

A tecnologia através de redes neurais artificiais (ANNs – *Artificial Neural Networks*) é uma das ferramentas de Inteligência Computacional (*soft computing*), que tem contribuído para o desenvolvimento em diversas áreas do conhecimento humano. A flexibilidade, a capacidade de aprender e generalizar a partir de exemplos, a eficiência computacional, a tolerância à falhas de suas unidades elementares (neurônios), a robustez quanto à escolha de seus parâmetros, são algumas das características que conduziram a uma popularização das redes neurais artificiais, com aplicações tanto em *hardware* quanto em *software*. Em particular, este artigo descreve a implementação computacional das redes neurais como uma ferramenta numérica alternativa para a solução de problemas de engenharia – como elas são incorporadas em programas de CAD (*Computer Aided Design*). Neste sentido, são descritas aplicações específicas, para análise, projeto e otimização na área de Engenharia Elétrica. Os modelos através de redes neurais são aplicados para a análise de antenas, projeto de dispositivos de microondas e simulação de circuitos digitais não lineares. As técnicas para o desenvolvimento de modelos neurais (*neuromodeling*) são revistas. Um estudo comparativo é realizado em termos de precisão e custo computacional, mostrando os critérios de desempenho dos modelos neurais e de outros, previamente estabelecidos na literatura especializada. Os resultados apresentados demonstram o potencial das redes neurais como uma ferramenta numérica flexível e eficiente, que, quando incorporada em um ambiente de CAD, resulta em ganho de precisão e redução de custo computacional.

PALAVRAS-CHAVE: engenharia elétrica; redes neurais; modelos de dispositivos; análise de circuitos

1. INTRODUÇÃO

Nas últimas duas décadas a tecnologia através de redes neurais artificiais (ANN's – *Artificial Neural Networks*) tem emergido e agora está sendo aplicada em diferentes áreas da engenharia, tais como: reconhecimento da fala, controle, telecomunicações, sensoriamento remoto, reconhecimento de padrões, etc, (Patnaik e Mishra, 2000). Apesar de uma rede neural servir para o entendimento das funções do cérebro, os engenheiros estão interessados em redes neurais para a solução de problemas. Nesta direção, a tecnologia através de ANNs, uma das ferramentas de Inteligência Computacional, tem contribuído para o desenvolvimento, por exemplo, em diferentes áreas da engenharia elétrica, mecânica e química.

Diante do grande leque de aplicações voltadas para a engenharia e dos diversos tipos existentes de configurações de redes neurais, neste estudo a metodologia de redes neurais foi aplicada apenas para uma classe de problemas de modelagem encontrados na área de engenharia de microondas. Para tanto, considerou-se o desenvolvimento de modelos neurais (*neuromodeling*) de dispositivos/circuitos de RF/microondas para sistemas de telecomunicações. Os conceitos sobre redes neurais abordados se aplicam diretamente em outras áreas e aplicações para a engenharia. Desta forma, procurou-se enfatizar as técnicas de treinamento existentes para *neuromodeling*, enquanto outros tópicos da metodologia foram menos enfocados.

Desde a década de 1990 as redes neurais têm sido aplicadas para a engenharia de microondas, veja (Watson e Gupta 1996), (Creech et. al., 1997) e (Veluswami et. al., 1997). No estágio tecnológico atual, tornou-se comum o uso de ferramentas computacionais sofisticadas para projeto, análise e simulação dos dispositivos e circuitos componentes dos sistemas de telecomunicações. A indústria voltada para este mercado dinâmico, com ênfase em baixos custos, demanda, cada vez mais, por ferramentas de CAD para dispositivos e circuitos de RF/microondas.

Em geral, o desenvolvimento de um programa de CAD para dispositivos de microondas requer simplificações numéricas de seus modelos físicos/EMs (eletromagnéticos), por exemplo, através de circuitos equivalentes. Neste caso, os modelos empíricos/analíticos aumentam a eficiência computacional da simulação numérica. Um compromisso entre custo computacional e precisão dos resultados é a questão principal na escolha destes modelos.

Neste contexto, as ANNs treinadas a partir de resultados EMs precisos são bastante apropriadas para o desenvolvimento de programas CAD. Em geral, os modelos neurais associam a precisão dos simuladores eletromagnéticos e a eficiência computacional dos modelos empíricos, (Silva, 2002). Desta forma, os modelos neurais se estabeleceram com aplicações nestas e em diversas outras áreas da engenharia, preenchendo a lacuna existente entre os modelos físicos e empíricos e incorporando as informações fornecidas por estes.

Este artigo reúne algumas aplicações de *neuromodeling* e algumas contribuições são feitas com relação às técnicas de treinamento e configurações de redes neurais, tais como: o método de mapeamento de espaços; o método dos modelos neurais ótimos; a rede modular RBF/MLP (*Radial Basis Functions/Multilayer Perceptrons*).

2. NEUROMODELING – FUNDAMENTOS

2.1 Neurônio Artificial e Redes Neurais Sem Realimentação

O tipo de neurônio mais utilizado em configurações de redes neurais é o *perceptron* de Rosenblatt (1958), cujo funcionamento tem suas origens no modelo não-linear do neurônio artificial proposto por McCulloch-Pitts (1943). Neste modelo, o neurônio é uma unidade de processamento de sinais constituída por um conjunto de conexões de entrada (ou pesos), um somador e uma função ativação, que pode ser linear ou não-linear, conforme ilustrado na Fig. 1(a). Em conjunto, o somador e os pesos efetuam uma combinação linear dos sinais de entrada, designados por x_i , $i = 0, 1, \dots, N_i$, cujo resultado corresponde ao nível de atividade interna ou potencial de ativação do neurônio, a_j , conforme definido em (1). Por sua vez, o sinal de saída do neurônio, y_j , é a resposta da função ativação ϕ ao potencial de ativação a_j , (2).

$$a_j = \sum_{i=0}^{N_i} w_{ji} \cdot x_i \quad (1)$$

$$y_j = \phi(a_j) \quad (2)$$

em que, $x_0 = +1$ corresponde ao potencial de polarização do neurônio.

Na configuração de uma rede neural sem realimentação (FNN – *FeedForward Neural Network*) os neurônios artificiais estão reunidos em camadas. Cada neurônio de uma camada está conectado a todos os neurônios da camada anterior, conforme a configuração ilustrada na Fig. 1(b). A propagação dos sinais ocorre no sentido direto: da camada de entrada para a camada de saída, passando através das camadas ocultas da FNN, (Haykin, 1994).

A camada de entrada de uma FNN é composta de neurônios sensores, que captam os sinais de entrada, adequando-os ao processamento interno na rede neural. O funcionamento da camada de entrada pode ser pensado como um pré-processamento, normalização, escalonamento, etc. Os neurônios ocultos são os responsáveis pela representação das características presentes nas entradas, enquanto os neurônios de saída geram as respostas da rede neural.




Fig. 1 (a) Modelo não-linear de um neurônio artificial. (b) Configuração de uma FNN com duas camadas ocultas.

2.2 Metodologia Através de Redes Neurais

De um modo geral, o projeto de uma rede neural consiste de três etapas principais: configuração – como a rede neural é organizada em camadas e como estas estão conectadas; aprendizado – como a informação é armazenada na rede neural; evocação – como a informação armazenada é recuperada da rede neural, (Haykin, 1994).

Na simulação computacional do processo de aprendizado supervisionado através da correção do erro, um algoritmo de treinamento é utilizado na adaptação dos pesos de uma rede neural. O erro, $e(n)$, definido em (3), é a diferença entre a resposta desejada, $d(n)$, e a saída rede neural, $z(n)$, Fig 2(a).

$$e(n) = z(n) - d(n) \quad (3)$$

O índice n representa cada instante de ativação da rede neural com a apresentação de um exemplo do conjunto de treinamento, que consiste de um par entrada × saída $(x(n); d(n))$, Fig. 2(a). Por sua vez, uma época de treinamento, simbolizada pelo índice t , corresponde à apresentação de todos os exemplos do conjunto de treinamento, $n = 1, 2, \dots, N$, em que, N é o número total de exemplos. O objetivo do treinamento supervisionado é a minimização do erro médio quadrático (MSE – *Mean Square Error*), definido em (4).

$$E(t) = \frac{1}{N} \sum_{n=1}^N \frac{1}{2} e(n)^2 \quad (4)$$

Atualmente existe uma variedade enorme de algoritmos para o treinamento das redes neurais, através de diferentes técnicas de otimização, tais como, o método do gradiente, algoritmos genéticos, etc. Os algoritmos mais populares para o treinamento de uma ANN são derivados do algoritmo *backpropagation*, (Rumelhart et. al., 1986). Dentre os algoritmos da família *backpropagation*, o RPROP – *resilient backpropagation* (Riedmiller e Braun, 1993), tem-se

mostrado bastante eficiente e foi utilizado nas simulações apresentadas neste artigo. Os critérios de parada do algoritmo de treinamento são definidos em termos do número máximo de épocas e/ou erro mínimo desejado. Após o treinamento, a rede neural deve ser submetida a um conjunto de teste para se verificar a capacidade de generalização do modelo neural para valores diferentes daqueles dados no conjunto de treinamento, por exemplo, em partes da região de interesse onde se tem pouco (ou nenhum) conhecimento sobre o dispositivo/circuito modelado. Tendo sido aprovada no teste, a rede neural treinada pode ser considerada como um modelo do tipo “caixa-preta”, que estima as saídas que o dispositivo/circuito apresentaria para novos valores das entradas, Fig. 2(b).

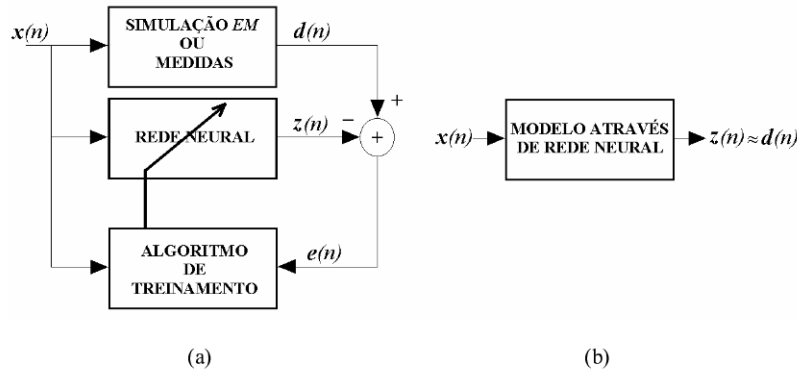


Fig. 2 (a) Representação do processo de aprendizado supervisionado. (b) Modelo através de rede neural.

2.2 Tipos de Redes Neurais Sem Realimentação

A configuração utilizada neste estudo, representada na Fig. 3, apresenta N_i nós de entrada, N_h neurônios ocultos, e um neurônio de saída. Esta configuração simples, com apenas uma camada oculta, é suficiente para a modelagem de uma ampla classe de dispositivos/circuitos, e, tem suas bases no teorema da aproximação universal (Hornik et. al., 1990), (Poggio e Girosi, 1990). Em termos matemáticos, o processamento de sinais (ou computação no sentido direto) realizado por esta configuração de FNN pode ser descrito através das expressões (5)-(6); para simplificar a notação o índice n foi omitido.

$$y_j = \phi(a_j) \quad j = 0, 1, \dots, N_h \quad (5)$$

$$z = a_k = \sum_{j=0}^{N_h} w_{kj} \cdot y_j \quad k = 1 \quad (6)$$




Fig. 3 Configuração da rede neural FNN utilizada.

A configuração da Fig. 3 pode ser usada para representar diferentes tipos de FNNs, porque estas redes com apenas uma camada oculta diferem entre si exatamente pela maneira na qual são definidas as suas funções ativação ϕ , (3). Responsáveis pelo comportamento não-linear dos neurônios ocultos, estas funções ativação representam na rede neural as características presentes nos sinais de entrada, $\mathbf{x}^T = [x_0 \cdots x_i \cdots x_{N_i}]$. Portanto, a saída y_j de cada neurônio oculto depende das medidas de similaridade utilizadas no cálculo dos potenciais de ativação a_j , conforme definido concisamente em (3). Em (4) considerou-se um neurônio de saída linear, por isso a saída z da FNN corresponde exatamente ao potencial de ativação do neurônio de saída a_k , calculado através de uma combinação linear das saídas provenientes da camada oculta.

Duas funções de ativação bastante utilizadas na camada oculta são as funções *sigmóide-logística* (para redes do tipo MLP–*multilayer perceptrons*) e a *Gaussiana* (para redes do tipo RBF–*radial basis functions*), definidas em (5) e (6), respectivamente, (Haykin, 1994).

$$\phi(a_j) = \frac{1}{1 + e^{-a_j}} \quad a_j = \mathbf{w}_j \cdot \mathbf{x} = \sum_{i=0}^{N_h} w_{ji} \cdot x_i \quad (5)$$

$$\phi(a_j) = e^{\left(-a_j/\sigma_j^2\right)} \quad a_j = \|\mathbf{x} - \mathbf{w}_j\| = \sqrt{\sum_{i=1}^{N_i} (x_i - w_{ji})^2} \quad (6)$$

Em (5) e (6), observa-se que, para o cálculo dos potenciais de ativação a_j são usadas duas medidas de similaridade diferentes entre os vetores \mathbf{x} e \mathbf{w}_j : produto escalar (para a rede MLP) e distância Euclidiana (para a rede RBF), respectivamente. A distância Euclidiana é medida entre as entradas e os centros \mathbf{w}_j das funções radiais de base, (6).

As diferenças entre as redes MLP e RBF lhes conferem características particulares, quando estas são usadas como modelos não-lineares. Enquanto uma rede MLP usando funções ativação *sigmóide* realiza uma aproximação global de toda a região de interesse, uma rede RBF Gaussiana realiza uma aproximação local e por partes da região de interesse, cujos limites são dados pelas larguras σ_j^2 de cada função radial Gaussiana. Convém lembrar que, na configuração da Fig. 3, para a rede MLP tem-se $x_0 = +1$ e para a rede RBF, $x_0 = 0$.

A computação realizada por uma FNN com a configuração da Fig. 3 pode ser pensada como uma expansão em funções de base de um mapeamento entrada×saída multidimensional e não-linear, onde as funções ativação da camada oculta correspondem as funções de base. Alguns trabalhos publicados nesta linha de pesquisa indicam realmente que o uso de funções sigmóides ou radiais não garante a melhor generalização nem treinamento rápido de redes neurais (Duch e Janckowisk, 1997). A escolha das funções ativação deve influenciar diretamente a complexidade e o desempenho das redes neurais, (Duch e Janckowisk, 1998). Uma taxonomia de funções ativação (ou de transferência) é dada em (Duch e Janckowisk, 2000).

Neste contexto, foram dadas algumas contribuições que usam funções ativação senoidais. Por exemplo, a rede de funções *sample* (SFNN – *sample functions neural network*) é uma contribuição original, que tem sido aplicada com sucesso na área de engenharia de microondas, (Silva, 2002). A escolha da função ativação do tipo $sample(x) = sen(x)/x$, (7), para os neurônios ocultos da SFNN teve motivação nas aplicações desta função para reconstrução de sinais.

$$y_j = \phi(a_j) = sample(\sigma_j \cdot a_j) \quad a_j = \|\mathbf{x} - \mathbf{w}_j\|^2 \quad (7)$$

Outra contribuição nesta área foi proposta recentemente com o desenvolvimento da rede DSFNN – *Damped Sinusoid Neural Network* para a modelagem de antenas circulares, veja seção 3.3, onde estas redes são usadas para aproximar integrais de funções de Bessel.

3. APLICAÇÕES

As técnicas de treinamento evoluíram bastante a partir do método convencional, no qual apenas uma rede neural treinada diretamente a partir de resultados precisos (sem informação adicional) é usada no modelo neural. Dentre as metodologias usadas para o desenvolvimento de modelos neurais, as redes neurais modulares, com várias ANNs organizadas em camadas, e o desenvolvimento de modelos híbridos, que usam modelos empíricos e redes neurais em conjunto, têm recebido atenção especial na literatura especializada, veja (Zhang e Gupta, 2000), (Silva, 2002). Esta seção reúne algumas das técnicas de treinamento usadas em aplicações de *neuromodeling*.

3.1 Método Convencional – Rede MLP

Através do método convencional uma rede neural é treinada para aproximar a resposta de um modelo preciso (físico/EM) em uma dada região de interesse. A Fig. 4 ilustra o método convencional aplicado para o treinamento de uma ANN como modelo da característica $I_{DS} = f(V_{GS}, V_{DS})$ de um transistor do tipo GaAs MESFET (*Galium Arsenide Metal Semiconductor Field Effect Transistor*). Neste caso as entradas do modelo são as tensões através dos terminais (fonte, porta e dreno) do transistor V_{GS} e V_{DS} ; a saída do modelo é a corrente de dreno I_{DS} .

Se a rede neural for treinada com um número suficiente de exemplos de treinamentos, até que seja encontrado um valor ótimo para seus pesos, simbolizado por w , a ANN serve como um modelo rápido e preciso na região de interesse pré-estabelecida. A complexidade da rede neural (quantidade de parâmetros internos, neste estudo, o número de neurônios ocultos) deve ser selecionada, de tal forma que: a ANN apresente a precisão desejada e uma boa generalização na região de interesse, onde o modelo do mapeamento entrada \times saída foi definido.




Fig. 4 Método convencional de treinamento de uma rede neural como modelo de um transistor MESFET.

Os transistores de microondas do tipo GaAs MESFET são dispositivos ativos complexos internamente. Os modelos empíricos/analíticos são incapazes de descrevê-los de forma precisa e sob todas as condições. Resultados precisos só são obtidos através de um modelo físico preciso (método numérico), que, em geral, acrescentam um excessivo custo computacional aos simuladores de circuito, tornando seu uso proibitivo, (Silva et al., 2001).

Neste contexto, a aplicação de uma rede MLP como modelo de um transistor do tipo GaAs MESFET foi proposta, com a seguinte configuração: três nós de entrada, $N_i = 3$, uma camada oculta com dez neurônios, $N_h = 10$, e um neurônio de saída linear, (Silva et al., 2002). No treinamento desta rede MLP com o algoritmo RPROP, foram utilizados $N = 33$ exemplos para representar a característica $I_{DS} = f(V_{GS}, V_{DS})$ do transistor MESFET.

Uma comparação entre as respostas dos modelos implementados para o transistor MESFET é apresentada na Fig. 5. Consta-se que o modelo neural MLP é mais preciso do que os modelos empíricos, aproximando com maior exatidão os resultados precisos do modelo numérico de análise 2D.

A fim de se testar a capacidade de generalização do modelo MLP, simulou-se a resposta transitória do circuito de entrada de uma porta lógica com dois transistores GaAs MESFET, Fig. 6(a). Para tanto foi utilizado o circuito não-linear equivalente proposto por Curtice (1980), Fig. 6(b). Os resultados obtidos na análise transitória são apresentados na Fig. 7(a), considerando-se cada modelo e uma entrada pulsada em 1 Gbit/s. A tensão de saída do circuito porta lógica, obtida a partir do modelo de Schichman e Hodges (1968), incorporado ao simulador de

circuitos SPICE2, apresenta erros no tempo de subida, no ganho e no atraso de propagação. Para o modelo de Curtice (1980), os resultados são razoáveis para um modelo empírico. Em relação ao modelo preciso do MESFET, o modelo neural MLP é o que aproxima com maior exatidão a resposta transitória, o que valida este modelo neural.

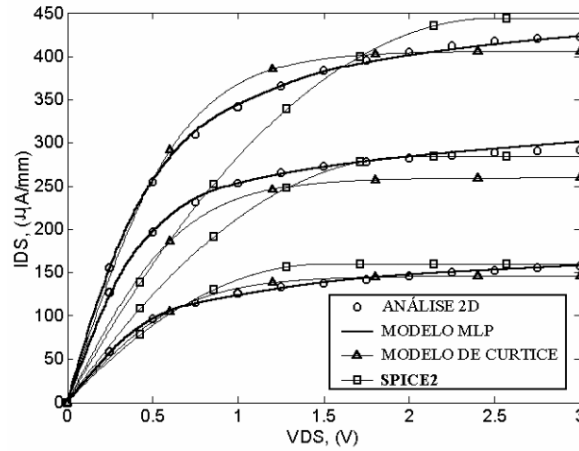


Figura 5. Curvas características de um transistor de microondas GaAs MESFET.

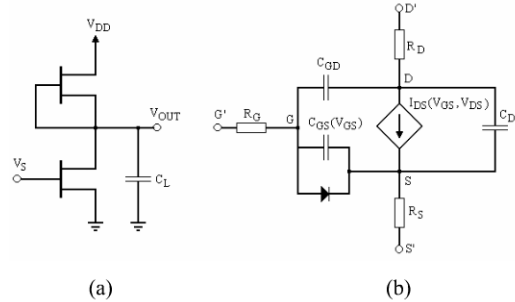
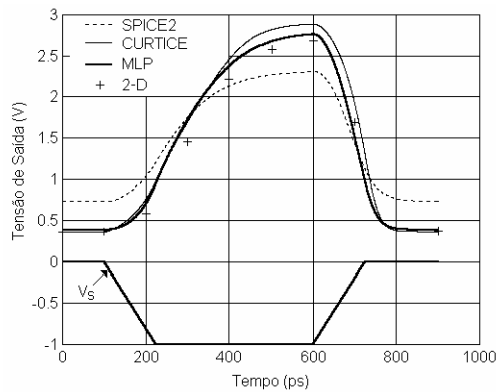
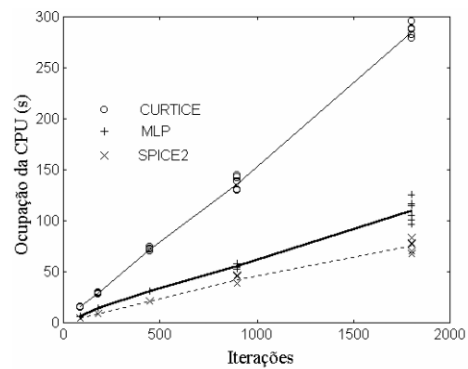


Figura 6. (a) Circuito de entrada de porta lógica. (b) Circuito equivalente para o GaAs MESFET.

A eficiência computacional de cada um dos modelos simulados foi medida em função do número de iterações do método de Newton-Raphson, usado na análise transitória do circuito da Fig. 6(a). Os resultados obtidos são mostrados na Fig. 7(b). Neste estudo comparativo, verificou-se que, o custo computacional do modelo MLP é inferior ao do modelo de Curtice e ligeiramente superior ao do modelo usado no programa SPICE 2.



(a)



(b)

Fig. 7 (a) Respostas pulsadas a 1,0 Gbit/s. (b) Custo computacional dos modelos.

3.2 Mapeamento de Espaços – Rede MLP

Estratégias inovadoras, através da inclusão de modelos empíricos, têm sido propostas para solucionar problemas de modelagem na área de microondas, visando diminuir a quantidade de dados de treinamento e a complexidade da rede neural, bem como aumentar a capacidade de generalização do modelo neural. Estão incluídos nos principais métodos híbridos: o EM-ANN, o KBNN (*knowledge based neural network*), o PKI (*Prior Knowledge Information*), e o SM-ANN (Space Mapping), (Zhang e Gupta, 2000), (Rayas e Sanchez, 2001), (Silva, 2002).

No método de mapeamento de espaços SM-ANN a habilidade das redes neurais para a aproximação de mapeamentos multidimensionais não-lineares é explorada. A rede neural é responsável pelo mapeamento P entre as entradas do modelo preciso e as entradas do modelo empírico, (8), tal que, as respostas dos modelos, R_f e R_e respectivamente, sejam aproximadas. Uma ilustração do método SM-ANN é apresentada na Fig 8.

$$x_e = P(x_f) \Rightarrow R_e(x_e) \approx R_f(x_f) \quad (8)$$




Fig. 8 Método híbrido SM-ANN.

O método SM-ANN foi aplicado para a modelagem da junção T em linha de microfita ilustrada na Fig. 9(a), com os seguintes parâmetros de projeto $x = [\omega \ W_1 \ W_2 \ \ell_1 \ \ell_2 \ h \ \epsilon_r]^T$: frequência ω ; larguras W_1 e W_2 e comprimentos ℓ_1 e ℓ_2 das fitas condutoras; altura h e permissividade relativa ϵ_r do substrato dielétrico.




Fig. 9 (a) Junção-T em linha de microfita. (b) Circuito equivalente.

O modelo empírico proposto por Gupta et al (1981) foi empregado para aproximar o comportamento da junção-T, através do circuito equivalente, Fig. 9(b). A partir da expressão dos parâmetros do circuito equivalente para a junção-T, assumindo-se uma impedância da linha principal (porta 1/porta 2) de 50Ω e $\epsilon_r = 9,9$, obtém-se a representação através da matriz de espalhamento, que descreve a transmissão/reflexão de sinais nas três portas da junção-T, (SILVA, 2002).

Os dados do modelo preciso (parâmetros de espalhamento), usados no treinamento das ANNs, foram obtidos através de resultados de simulações do programa Sonnet's em^{TM} . Os seguintes valores para os parâmetros físicos da junção-T foram considerados: $\epsilon_r = 9,9$, $W_1 = h = 508 \mu m$, $\ell_1 = 2,0 \text{ mm}$, $\ell_2 = 1,8 \text{ mm}$. Neste caso, o modelo empírico de Gupta et al (1981) leva a respostas aceitáveis apenas em baixas frequências, inferiores a 2,0 GHz.

A Fig. 10 mostra os resultados precisos obtidos através do simulador Sonnet's em^{TM} , com a variação da largura da microfita W_2 . Foram usados 33 exemplos de treinamento ($W_2 = [127 \ 254 \ 508] \mu m$) e 22 exemplos de teste ($W_2 = [203 \ 381] \mu m$). A resposta do modelo híbrido SM-ANN até 20 GHz também é incluída na Fig. 10, mostrando uma boa aproximação para os dados de treinamento e uma razoável generalização para os dados de teste.

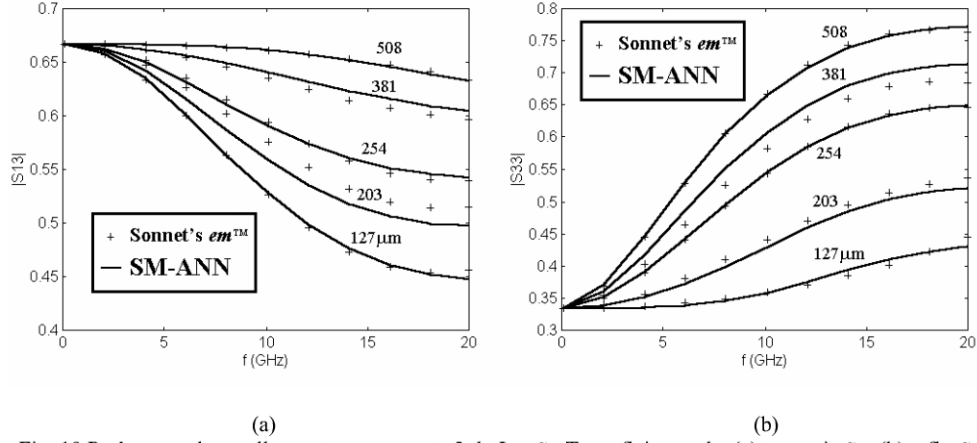


Fig. 10 Parâmetros de espalhamento para a porta 3 da Junção-T, coeficientes de: (a) transmissão; (b) reflexão.

3.3 Modelos Neurais Ótimos – Rede DSFNN

Nesta seção, a configuração da Fig. 3 é utilizada para a elaboração de modelos analíticos, rápidos e precisos, definidos através de expansões em funções de base (funções ativação, ϕ), para aproximação/interpolação de uma classe de funções especiais. Neste método, uma rede neural é treinada para cada função de base escolhida a fim de se classificar quais das funções de base são mais apropriadas para o modelo neural. Os problemas encontrados neste método, como a escolha do número e do tipo de funções de base, bem como, a otimização dos seus parâmetros, são repassados para um problema de treinamento em rede neurais. Após um processo de tentativa e erro é possível que seja encontrada uma rede neural, que atenda a precisão e eficiência desejada para o modelo.

Para ilustrar a aplicação deste método para a elaboração de modelos neurais ótimos, considerou-se um modelo para descrever a diretividade de uma antena do tipo *loop*-circular. As expressões integrais para a resistência de radiação $R_r(\alpha)$ e para a diretividade $D(\alpha)$, para todo raio a da antena *loop*, podem ser encontradas em Balanis (2005). Por conveniência as fórmulas são reproduzidas aqui, (9) e (10), respectivamente. Para distribuições de corrente constante e co-senoidal na antena *loop*, as funções auxiliares $F_m(\alpha)$ and $T(\alpha)$ são dadas em (11) e (12), respectivamente.

$$R_r(\alpha) = 60(\pi\alpha)^2 T(\alpha) \quad (9)$$

$$D(\alpha) = F_m(\alpha)/T(\alpha) \quad (10)$$

$$F_m(\alpha) = \begin{cases} 2J_1^2(1.840) = 0.677, & \alpha > 1.840 \\ 2J_1^2(\alpha) & \alpha < 1.840 \end{cases} \quad I_\varphi = I_0 \quad (11)$$

$$1, \quad I_\varphi(\varphi) = I_0 \cos(\varphi)$$

$$T(\alpha) = \begin{cases} Q_{11}^{(1)}(\alpha), & I_\varphi = I_0 \\ \frac{1}{2} [Q_{00}^{(1)}(\alpha) - 2Q_{11}^{(1)}(\alpha)/\alpha^2 + Q_{22}^{(1)}(\alpha)], & I_\varphi(\varphi) = I_0 \cos(\varphi) \end{cases} \quad (12)$$

O objetivo é encontrar uma rede neural mínima como modelo para as integrais do tipo- Q em (12). A representação das integrais do tipo- Q foi definida por Savov (2006) e é dada em (13), usando a notação das funções de Bessel.

$$Q_{mn}^{(p)}(\alpha) = \int_0^{\pi/2} J_m[\alpha \sin(\theta)] J_n[\alpha \sin(\theta)] \sin^{(p)}(\theta) d\theta \quad (13)$$

Em que $\alpha = ka$, $k = 2\pi/\lambda$; a é o raio da antena *loop*; e $J_m(\cdot)$ é a função de Bessel de primeira característica e ordem m . Uma solução analítica geral para integrais do tipo- Q não está disponível em *handbooks* sobre integrais e funções especiais (Gradshteyn e Ryzhik, 1965), (Abramowitz e Stegun, 1970). Por outro lado sua computação é um problema numérico de difícil solução para antenas *loop* maiores, devido à rápida oscilação do integrando, e pode se tornar um tedioso e ineficiente exercício numérico. Entretanto, para $n = m$ e $p = 1$, é possível contornar este problema rescrevendo (13) através de uma integral simplificada (14), (Mahony, 2003).

$$Q_{nn}^{(1)}(\alpha) = \frac{1}{2\alpha} \int_0^{2\alpha} J_{2n}(t) dt \quad (14)$$

Além disso, uma aproximação analítica através de séries de funções de Bessel é dada em (15).

$$Q_{nn}^{(1)}(\alpha) = \frac{1}{\alpha} \sum_{k=n}^{\infty} J_{2k+1}(2\alpha) \quad (15)$$

A configuração da Fig. 3 com apenas um nó de entrada foi utilizada para a modelagem da relação definida em (14). Após a tentativa de diversas classes de funções de base incluindo as funções sigmoidais, exponenciais, polinomiais e senoidais, escolheu-se uma função de base do tipo seno-amortecido, definida em (16).

$$q_j(\mathbf{w}_j, \bar{\alpha}) = \frac{k_j}{\sqrt{|1 - \xi_j^2|}} \exp(-\xi_j \tau_j \bar{\alpha}) \cdot \sin(\omega_j \bar{\alpha} + \phi_j) \quad (16)$$

em que $\mathbf{w}_j = [k_j \ \xi_j \ \tau_j \ \omega_j \ \phi_j]^T$ designa o vetor de pesos da j -ésimo neurônio oculta; e $0 \leq \bar{\alpha} \leq 1$ é a entrada normalizada da rede. A função ativação seno-amortecido, definida com cinco parâmetros livres, é bastante flexível e assume formas variadas dependendo dos valores de seus parâmetros.

A rede neural resultante desta pesquisa, denominada DSFNN – *Damped-Sinusoid Functions Neural Network*, realiza eficientes aproximações para as integrais do tipo- Q . A computação realizada pela rede DSFNN é dada em (17). As aproximações do modelo DSFNN para as integrais do tipo- Q são obtidas através de (18).

$$q_{nn} = \left[1 - \sum_{j=0}^{N_h-1} q_j(\mathbf{w}_j, \bar{\alpha}) \right] \quad (17)$$

$$Q_{nn}^{(1)}(\alpha) \approx \frac{1}{\alpha} q_{nn} \quad (18)$$

A resistência de radiação e a diretividade da antena *loop*-circular foram calculadas usando quatro aproximações: integração numérica, expressões aproximadas, séries de funções de Bessel (com 30 termos), e através da rede DSFNN (com 10 funções de base). A integração numérica de (14) através da quadratura de Lobatto foi utilizada para fornecer os valores precisos e para verificar a precisão das outras aproximações.

Os resultados obtidos, Fig. 11(a), mostram a excelente aproximação do modelo DSFNN para os valores das integrais do tipo- Q (considerando $n = 0, 1, 2$, e 1000 pontos de teste na faixa de $0.1 \leq \alpha \leq 16$). A Fig. 11(b) mostra os resultados obtidos para a diretividade da antena *loop*-circular (considerando duas distribuições de corrente: constante e co-senoidal e a faixa de $0.1 \leq \alpha \leq 10$).

Considerando a distribuição de corrente constante na antena *loop*-circular e a faixa de $0.1 \leq \alpha \leq 25$, a Fig. 12(a) mostra os erros de cada modelo nas aproximações da diretividade. Pode-se verificar que o modelo DSFNN apresenta uma precisão intermediária. Enquanto as expressões aproximadas apresentam um erro máximo de 0.2 dB, [3], o máximo erro apresentado pelo modelo DSFNN não passa de 0.00006 dB.

O custo computacional de cada aproximação para o cálculo da resistência de radiação é apresentado na Fig. 3(b). A eficiência computacional do modelo DSFNN se equipara a apresentada pelo modelo de expressões aproximadas. Em relação à computação das séries de funções de Bessel, (15), o modelo DSFNN é no mínimo dez vezes mais rápido.

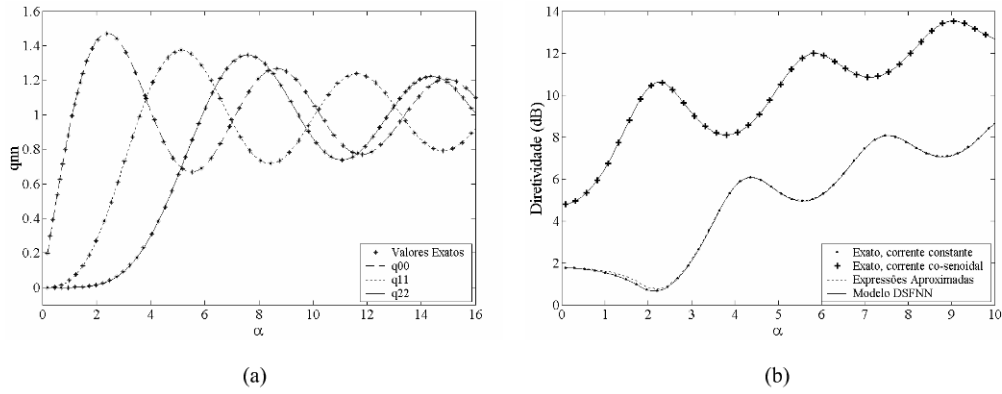



Fig. 11 (a) Aproximação do modelo DSFNN para as integrais do tipo- Q . (b) Diretividade da antena *loop*-circular – computação através da quadratura de Lobatto (exato), de expressões aproximadas e do modelo DSFNN.



(a)

(b)

Fig.12 Comparação entre os modelos implementados para análise da antena *loop*-circular:
(a) erros na avaliação da diretividade; (b) custos computacionais na avaliação da resistência de radiação.

3.4 Rede Modular RBF/MLP

Uma rede FNN com uma camada oculta nem sempre é suficiente para a modelagem de mapeamentos multidimensionais e não-lineares. Nestes casos, o aumento da complexidade da rede neural resulta um treinamento lento e a propriedade de generalização não é garantida. Por outro lado, a escolha adequada do número de neurônios da camada oculta torna-se crítica. Para contornar estes problemas, as redes neurais modulares foram propostas. Baseadas no princípio “*dividir e conquistar*”, uma configuração modular permite a divisão de um problema de aprendizado em problemas menores e mais simples de serem resolvidos, (Passos, 2006).

Uma contribuição nesta área foi dada com a proposta de uma rede modular RBF/MLP composta de duas redes RBFs especialistas e de uma rede MLP de saída, todas com a configuração da Fig. 3, em que, as saídas das redes especialistas são aplicadas às entradas adicionais da rede de saída, que fornece a resposta do modelo neural RBF/MLP, conforme ilustrado na Fig. 13. As redes RBFs são treinadas a partir dos valores inicial e final da região de interesse, enquanto para o treinamento da rede MLP, todos os dados de treinamento são utilizados, Fig. 14.

A metodologia através da rede modular RBF/MLP possui algumas vantagens, tais como: a divisão do problema de aprendizado entre as FNNs da estrutura modular; a redução da complexidade de cada FNN individual; o aumento da eficiência e da consistência do treinamento supervisionado; aumento da capacidade de generalização do modelo.

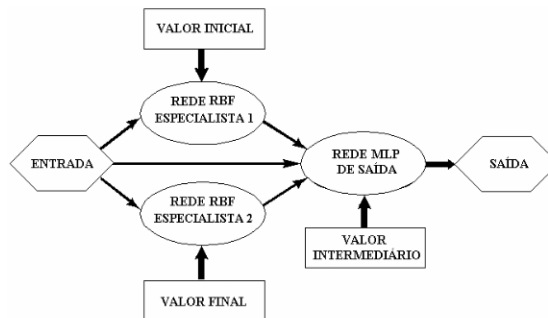


Fig. 13 Configuração da rede modular RBF/MLP.




Fig. 14 Ilustração da região de interesse.

A rede RBF/MLP tem sido aplicada com sucesso para a modelagem de dispositivos de microondas e ópticos, (Passos, 2006). Em particular destacam-se as suas aplicações para dispositivos com estruturas periódicas denominadas PBG – *Photonic Band-Gap*, (Passos et. al, 2006). A Fig. 15 mostra os resultados de aproximação/generalização obtidos através da rede RBF/MLP para a modelagem do campo elétrico em função da frequência no interior de um guia de ondas retangular UC-PBG (*Uniplanar Compact*).

Com o objetivo de se verificar a capacidade generalização da rede RBF/MLP, dois modelos neurais através de uma rede RBF e de uma rede MLP também foram desenvolvidos para o problema do guia de ondas UC-PBG. Os resultados obtidos são apresentados na Fig. 16, onde a capacidade de generalização de cada modelo neural em função do número de neurônios ocultos é medida em termos do erro médio quadrático (MSE) obtido para os dados do conjunto de teste. Como era de se esperar, o treinamento mais consistente das redes na estrutura modular resulta em um aumento da capacidade de generalização do modelo neural RBF/MLP.

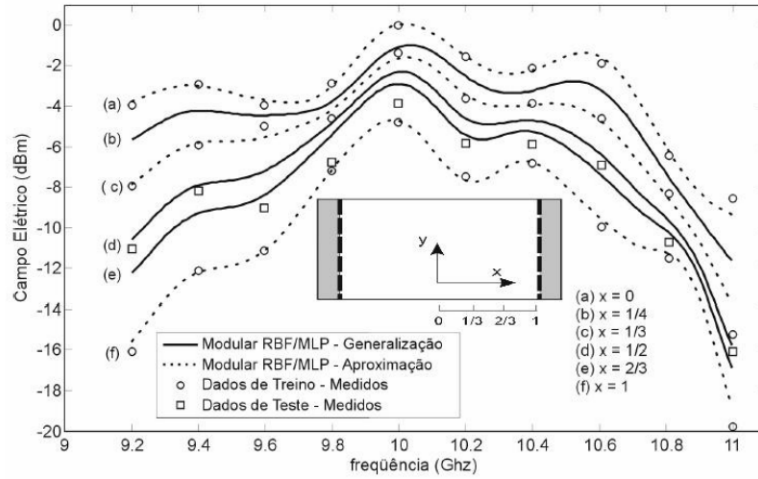


Fig. 15. Resposta do modelo RBF/MLP para o guia de ondas com paredes UC-PBG.

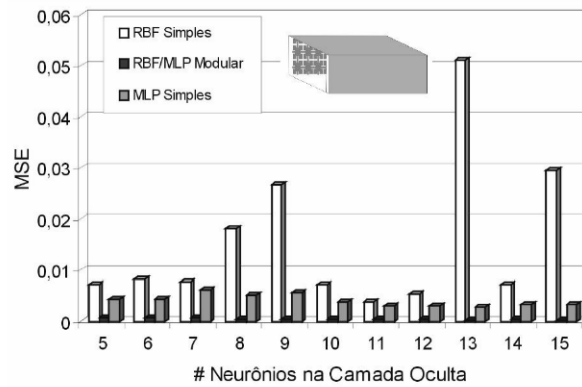


Fig. 16 Comparação entre dos modelos para o guia de ondas UC-PBG através das redes MLP, RBF e modular RBF/MLP.

4. CONCLUSÕES

Com a exploração de diferentes técnicas de treinamento de redes neurais desenvolvidas na última década, este artigo reuniu algumas das aplicações da metodologia de *neuromodeling* utilizando as ANNs como ferramentas numéricas para a engenharia, em particular para circuitos/dispositivos de RF/microondas. Algumas contribuições originais foram descritas, tais como: o método híbrido SM-ANN, o método dos modelos neurais ótimos e a rede neural modular RBF/MLP.

Três conclusões interessantes podem ser extraídas desta pesquisa. (i) Verificou-se que a utilização das redes MLP e RBF, as mais comuns, nem sempre resulta em um treinamento eficiente nem garante a capacidade de generalização dos modelos neurais resultantes. (ii) A escolha das funções ativação de uma FNN com uma camada oculta influencia decisivamente no desempenho do modelo neural; a priori, não existe uma escolha que seja adequada para qualquer tipo de problema de modelagem. (iii) O uso de informação adicional através de modelos híbridos, bem como, a divisão do problema de treinamento através de redes modulares, aumenta a eficiência e a consistência do treinamento, aumentando a capacidade de generalização dos modelos neurais resultantes.

5. REFERÊNCIAS BIBLIOGRÁFICAS

- Abramowitz, M. and Stegun, I. A., **Handbook of Mathematical Functions**, Dover, New York, 1970.
- Balanis, C. A., **Antenna Theory Analysis and design**, Wiley-Interscience, New Jersey, 2005
- Creech, G. L., et al., **Artificial neural networks for fast and accurate EM-CAD of microwave circuits**, IEEE Trans. on Microwave Theory and Techniques, v. MTT-45, p. 794-802, Mai, 1997.
- Curtice, W. R. **A MESFET Model for Use in the Design of GaAs Integrated Circuits**. IEEE Trans. on Microwave Theory and Techniques. v. 28, p. 448-456, 1980.
- Gradshteyn, I. And Ryzhik, I., **Tables of Integrals, Series and Products**, Academic Press, New York, 1965.
- Gupta, K. C., Garg, R., Chadha, R., **Computer-Aided Design of Microwave Circuits**, Massachusetts: Artech House, 1981.
- Haykin, S., **Neural Networks: A Comprehensive Foundation**. New York: Macmillan College Publishing Company, 1994. 696 p.
- Hornik, K., Stinchcombe, M., e White, H., **Multi-layered feed-forward neural networks are universal approximations**, Neural Networks, v. 2, p. 259-266, 1990.
- Mahony, J. D. **A Comment on Q-Type Integrals and Their Use in Expressions for Radiated Power**. IEEE Antennas and Propagation Magazine, Vol. 45, No. 3, 127-128, 2003.
- McCulloch, W. S., Pitts, W. **A Logical Calculus of the Ideas Immanent in Nervous Activity**. Bulletin of Mathematical Biophysics, v. 5, p. 115-133, 1943.
- Passos, M. G., **Modelos de Dispositivos de Microondas e Ópticos através de Redes Neurais Artificiais de Alimentação Direta**. Dissertação de Mestrado, Universidade Federal do Rio Grande do Norte, 88 f., 2006.
- Passos, M. G., Silva, P. H. da F. and Fernandes, H. C. C., **A RBF/MLP Modular Neural Network for Microwave Device Modeling**. International Journal of Computer Science and Network Security, v. 6., n. 5(A), p. 81-86, 2006.

Passos, M. G., Silva, P. H. da F. and Fernandes, H. C. C., **Modelos de Dispositivos com PBG Através de Redes Neurais Modulares RBF/MLP**. Anais do 12º Simpósio Brasileiro de Microondas e Optoeletrônica e 7º Congresso Brasileiro de Eletromagnetismo, 2006.

Patnaik, A., Mishra, R. K., **ANN techniques in microwave engineering**. IEEE Microwave, p. 55-60, Mar., 2000.

Poggio, T., Girosi, F. **Networks for approximation and learning**. Proceedings of the IEEE, 78, p. 1481-1497, Set., 1990.

Rayas-Sanchez, J. E., **Neural Space Mapping Methods for Modeling and Design of Microwave Circuits**, Tese de Doutorado, McMaster University, Jun., 2001.

Riedmiller, M.; Braun, H. **A Direct Adaptive Method for Faster Back-Propagation Learning: The RPROP Algorithm**. In: IEEE INTERNATIONAL CONFERENCE ON NEURAL NETWORKS, San Francisco. Proceedings, San Francisco: IEEE-ICNN, 1993. v.1, p. 586-591.

Rosenblatt, F. **The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain**. Psychological Review, v. 65, p. 386-408, 1958.

Rumelhart, D. E., Hinton, G. E., Williams, R. J. **Learning Internal Representations by Error Backpropagation**. Parallel Distributed Processing, Cambridge M.I.T. Press, v. 1, p. 318-362, 1986.

Savov, S. V. **An efficient Solution of a Class of Integrals Arising in Antenna Theory**. IEEE Antennas and Propagation Magazine, Vol. 44, No. 5, 98-101, 2002.

Schichman, H., Hodges, D. A. **Modeling and Simulation of Insulated-Gate Field-Effect Transistor Switching Circuits**. IEEE J. Solid-State Circuits, v. 3, p. 285-289, 1968.

Silva, P. H. da F.; Melo, M. A. B.; Neto, A. D. D. **Fast and Accurate Neural Network GaAs MESFET Model for Time-Domain Circuit Simulation**. IMOC - INTERNATIONAL MICROWAVE AND OPTOELECTRONICS CONFERENCE, Belém. Proceedings. Belém: SBMO/ IEEE MTT-S, 2001.

Silva, P. H. DA F. **Modelos Através de Redes Neurais Artificiais sem Realimentação para Dispositivos e Circuitos de RF/Microondas**. 2002. 166 f. Tese (Doutorado em Engenharia Elétrica) – Departamento de Engenharia Elétrica, UFCG, Campina Grande.

Silva, P. H. da F.; Melo, M. A. B.; Neto, A. D. D. **Using Neural Network Models for Efficient GaAs MESFET Time Domain Nonlinear Circuit Analysis**. In: INTERNATIONAL JOINT CONFERENCE ON NEURAL NETWORKS, Honolulu. Proceedings. Honolulu: WCCI-IEEE, 2002. v. 3, p. 2282-2287.

Zhang, Q. J., Gupta, K. C., **Neural Networks for RF and Microwave Design**, 1.ed. Norwood, MA: Artech House, Inc., 2000. 369 p.

Duch, W., Jankowski, N., **New Neural Transfer Functions**. Journal of Applied Mathematics and Computer Science, 7(3):639-658,1997.

Duch, W., Jankowski, N., **Survey of Neural Transfer Functions**. Neural Computing Surveys, 2:163-212,1999.

Duch, W., Jankowski, N., **Taxonomy of Neural Transfer Functions**. International Join Conference on Neural Networks, vol. 3, 477-484, 2000.

Veluswami, A., Nakla, M. S., Zhang, Q. J., **The application of neural networks to EM/based simulation and optimization of interconnects in high/speed VLSI circuits**. IEEE Trans. on Microwave Theory and Techniques, v. 45, p. 712-722, Maio, 1997.

Watson, P. M., Gupta, K. C., **EM-ANN models for microstrip vias and interconnects in datasets circuits**. IEEE Trans. Microwave Theory and Techniques, v. MTT-44, p. 2495-2503, Dez., 1996.